





TOMI

Teorija igara

prof. dr. sc. Tomislav Burić



VERZIJA OD: 17. LISTOPADA 2025.

PUBLISHED BY FER

WWW.FER.UNIZG.HR

Copyright © 2024 ZPM

Ova skripta se smije koristiti isključivo u osobne svrhe te se ne smije ni na koji način mijenjati ili umnožavati, kao ni prikazivati, izvoditi ili distribuirati u javnosti i drugim medijima, ili na bilo koji drugi način koristiti za bilo koju javnu ili komercijalnu svrhu.



Sadržaj

1	Strateške igre	5
1.1	Nashov ekvilibrij	6
1.2	Klasični primjeri igara	9
1.3	Primjeri iz ekonomije	11
2	Mješovite strategije	15
2.1	Bimatrične igre	15
2.2	Korelirane strategije i korelirani Nashov ekvilibrij	21
2.3	Simetrične igre i simetričan Nashov ekvilibrij	23
3	Igre sume-nula	27
3.1	Vrijednost igre sume-nula	27
3.2	Matrične igre	30
4	Ekstenzivne igre	35
4.1	Stabla odluke	35
4.2	Potpuni Nashov ekvilibrij	35
5	Kooperativne igre	37
5.1	Igre s prenosivom korisnosti	37
5.2	Igre s pogodbom	37
6	Literatura	39



1. Strateške igre

Teorija igara je moderna grana matematika koja proučava donošenje odluka u situacijama gdje su uključeni različiti sudionici, odnosno *igrači*, čije odluke utječu na ishode ostalih sudionika. Cilj teorije igara je da analizira kako igrači donose optimalne strategije u skladu sa svojim ciljevima pri čemu uzimaju u obzir poteze drugih igrača. Sama teorija se prvi put spominje u knjizi J. von Neumanna i O. Morgensterna *Teory of Games and Economic Behavior* iz 1944. godine u kojoj su autori definirali teoriju igara kao svaku interakciju između agenata koja je vođena skupom pravila koja određuju moguće poteze za svakog sudionika i skup ishoda za svaku moguću kombinaciju poteza. Najveći značaj teoriji i osnovne matematičke koncepte je postavio John Nash 1950. godine u svojoj disertaciji od samo 26 stranica. Nash je uveo pojam ravnoteže, odnosno *ekvilibrija*, te matematički modelirao nasumično ponašanje igrača kada nisu sigurni koji je najbolji potez za njih, tzv. *mješovite strategije*. Nashov ekvilibrij se pokazao najfascinantnijim i najkorisnijim matematičkim konceptom u teoriji igara, no trebalo je proći 40 godina da svijet i znanstvena zajednica prepozna njegov puni potencijal. John Nash je tek 1994. dobio Nobelovu nagradu za ekonomiju zbog svoje teorije ekvilibrija i značajnog doprinosa u teoriji igara. Od 1990ih se teorija igara razvija velikom brzinom i našla je primjenu u mnogim područjima znanosti, od ekonomije, politike i društvenih znanosti do biologije, informatike i računarstva, pogotovo nakon razvoja računala i moderne računarske znanosti. Nakon Nasha je još 16 znanstvenika dobilo Nobelovu nagradu za ekonomiju temeljeno na otkrićima iz teoije igara.

Dodatak

John Nash, 1928-2015, najpoznatiji je po svojim otkrićima u teoriji igara, no dao je veliki doprinos i u drugim područjima matematike. 2015. je dobio Abelovu nagradu (tzv. Nobelova nagrada za matematiku) za postignuća u teoriji nelinearnih parcijalnih diferencijalnih jednačbi. Nažalost poginuo je u automobilskoj nesreći vraćajući se s aerodroma upravo nakon primanja Abelove nagrade u Oslu. Život mu je obilježila velika borba sa shizofrenijom i među je rijetkim osobama koja je doživjela duboku starost usprkos

takvoj mentalnoj bolesti. Njegov život je uprizoren u filmu *Beautiful mind* koji je dobio Oscara za najbolji film 2001. godine s glumcem Russell Crowe u glavnoj ulozi Nasha.

Također ćemo napomenuti da teorija igara analizira samo situacije interaktivnog odlučivanja, odnosno koje uključuju više donositelja odluka, pri čemu odluka svakog od njih utječe na ishod svih ostalih. Takva interaktivnost upravo razlikuje teoriju igara od matematičke teorije odlučivanja kojoj je glavni fokus jedan donositelj odluke, odnosno teorija odlučivanja proučava individualno donošenje odluka u situacijama u kojima izbor pojedinca ne utječe na izbore drugih pojedinaca niti na njega utječu izbori drugih.

Za kraj istaknimo da se matematička analiza teorije igara u pozadini oslanja na jake pretpostavke o racionalnosti igrača. Odnosno, teorija igara i Nashov ekvilibrij očekuje da se svaki igrač ponaša racionalno i odabire potez koji maksimizira njegovu korisnost, te donosi odluke pod pretpostavkom da će i svi ostali igrači postupati racionalno. Zbog toga se teorija našla pod kritikama i da je zapravo neprimijenjiva u praksi. No usprkos tome teorija igara je i dalje važan i neizostavan alat u modeliranju i analizi interaktivnog odlučivanja te omoguću bolje razumijevanje konflikata, suradnje i konkurencije u različitim područjima znanosti.

1.1 Nashov ekvilibrij

Naša razmatranja ćemo krenuti s klasičnim uvodnim primjerom iz teorija igara, a to je zatvorenikova dilema.

■ **Primjer 1.1 — Zatvorenikova dilema.** Tomica i Perica su uhvaćeni pod sumnjom da su zajedno opljačkali banku. Svatko je ispitan odvojeno od drugog te ima dvije mogućnosti – negirati (N) ili priznati pljačku (P). Ako jedan prizna, a drugi negira zločin, prvi će zbog suradnje biti pušten na slobodu, a drugi će biti kažnjen sa 15 godina zatvora. Ako obojica priznaju, obojica će dobiti po 10 godina zatvora, no ako nijedan ne prizna, zbog nedostatka dokaza bit će zatvoreni na jednu godinu zbog manjeg prekršaja. S obzirom da nijedan ne zna što će drugi učiniti, treba li na ispitivanju priznati ili negirati zločin? Koju bi strategiju svaki od njih trebao odabrati da prođe što je bolje moguće? ■

Da bismo detaljnije analizirali navedenu *igru*, sve moguće ishode ćemo zapisati u tablicu. Općenito ćemo igre dva igrača zapisivati u matričnoj formi pri čemu će nam retci predstavljati poteze prvog igrača, stupci drugog igrača, a elementi matrice će biti ishodi za oba igrača. U ovom slučaju ćemo godine zatvora označiti s negativnim predznakom pa imamo:

$$\begin{array}{cc} & N & P \\ \begin{array}{c} N \\ P \end{array} & \begin{pmatrix} -1, -1 & -15, 0 \\ 0, -15 & -10, -10 \end{pmatrix} \end{array}$$

Prvi igrač (Tomica) može razmišljati na sljedeći način. S obzirom da ne zna što će učiniti drugi igrač (Perica), pogledajmo ishode u oba slučaja. Ako drugi igrač negira zločin, Tomica će ili dobiti jednu godinu zatvora ako također negira ili će biti pušten na slobodu ako prizna. Prema tome, više mu se isplati priznati zločin i ne završiti u zatvoru. Ako pak drugi igrač prizna zločin, Tomica će dobiti ili 15 godina zatvora ako negira ili 10 godina ako također prizna. I u ovom slučaju se Tomici više isplati priznati zločin jer će dobiti manje godina zatvora. Dakle u oba odgovora drugog igrača, prvi igrač će imati bolji ishod

ako prizna zločin. Možemo reći da je priznavanje zločina dominantna strategija jer s njom uvijek bolje prolazi ne znajući što će napraviti drugi igrač. Potpuno isto razmišljanje će imati i drugi igrač neznajući što će učiniti prvi, odnosno također mu se isplati priznati zločin. Tako smo došli do zaključka da je priznavanje zločina optimalna strategija za obojicu igrača, i da se u takvoj situaciji nijednom igraču ne isplati *jednostrano* promijeniti odluku jer ne može bolje proći. Možemo reći da su igrači u takvom ishodu *uravnoteženi*, odnosno to je upravo primjer Nashovog ekvilibrija.

Također primijetimo da takav ishod nije optimalan u kolektivnom smislu, odnosno oba igrača bi bolje prošla sa zajedničkom strategijom negiranja, no ako ne znaju što će drugi igrač učiniti i (sebično) gledaju isključivo vlastitu korisnost, dolaze u ravnotežno stanje s lošijim ishodom za obojicu. Zbog toga se zatvorenikova dilema još često naziva i paradoksom te pokazuje da Nashov ekvilibrij ne mora dati najbolje rješenje. Ključno je ovdje još jednom naglasiti da smo promatrali igru bez mogućnosti dogovora, odnosno svaki igrač je donio odluku bez znanja o odluci drugog igrača. Ukoliko igrači mogu dogovarati zajedničku strategiju da bi maksimizirali svoj ishod, govorimo o kooperativnim igrama i njima će se baviti tek u zadnjem poglavlju. Za sada sva razmatranja se odnose na isključivo nekooperativne igre.

Da bismo formalno definirali Nashov ekvilibrij, krenut ćemo prvo od formalne definicije igre, točnije **strateške igre**.

Definicija 1.1 Neka je $n \in \mathbb{N}$. **Strateška igra** s n igrača je uređeni par (A, u) , koji se sastoji od

- skupa strateških profila: za svaki $i \in \{1, \dots, n\}$, neka je A_i skup strategija igrača i , a skup $A = A_1 \times \dots \times A_n$ nazivamo **skupom strateških profila**
- funkcije korisnosti: za svaki $i \in \{1, \dots, n\}$, neka je $u_i : A \rightarrow \mathbb{R}$ funkcija korisnosti igrača i , a funkciju $u = (u_1, \dots, u_n) : A \rightarrow \mathbb{R}^n$ zovemo **funkcijom korisnosti**

U Zatvorenikovo dilemi je skup strategija svakog igrača $A_1 = A_2 = \{N, P\}$ pa imamo četveročlani skup strateških profila $A = \{(N, N), (N, P), (P, N), (P, P)\}$. Funkcije korisnosti svakog igrača su definirane sa $u_1(N, P) = -15, u_2(N, P) = 0, u_1(P, N) = 0, u_2(P, N) = -15, u_1(N, N) = u_2(N, N) = -1, u_1(P, P) = u_2(P, P) = -10$, odnosno zajednička funkcija korisnosti je $u(N, P) = (-15, 0), u(P, N) = (0, -15), u(N, N) = (-1, -1), u(P, P) = (-15, -15)$.

U analizi Zatvorenikove dileme smo se stavljali u poziciju jednog igrača i razmišljali koja je njegov optimalni potez u odnosu na fiksiran potez drugog igrača. Taj pristup koristimo i kod općenitih strateških igara, odnosno promatrat ćemo koja je najbolja strategija jednog konkretnog igrača i ako fiksiramo strategije svih ostalih igrača. U tu svrhu uvodimo oznaku (a_{-i}, a'_i) za strateški profil u kojem smo fiksirali strategije svih igrača osim strategije i -tog igrača, odnosno njegovu strategiju a_i smo zamijenili sa strategijom a'_i .

Definicija 1.2 Za stratešku igru (A, u) s n igrača i za strateški profil $a \in A$, neka za

proizvoljnog igrača i imamo fiksirane strategije ostalih igrača u oznaci:

$$a_{-i} = (a_1, \dots, a_{i-1}, a_{i+1}, \dots, a_n).$$

Nadalje, za $a \in A$ i $a'_i \in A_i$, uvodimo oznaku za strateški profil u kojem smo strategiju a_i zamijenili sa strategijom a'_i :

$$(a_{-i}, a'_i) = (a_1, \dots, a_{i-1}, a'_i, a_{i+1}, \dots, a_n).$$

Sada konačno možemo definirati Nashov ekvilibrij.

Definicija 1.3 Nashov ekvilibrij strateške igre (A, u) s n igrača je strateški profil $a^* \in A$ u kojem za svakog igrača i vrijedi:

$$u_i(a^*) \geq u_i(a_{-i}^*, a_i) \quad \text{za svaki } a_i \in A_i.$$

Možemo primijetiti da definicija u potpunosti odgovara razmatranju kod Zatvorenikove dileme: u Nashovom ekvilibriju a^* za **svakog** igrača vrijedi da je njegova korisnost veća ili jednaka od korisnosti svih ostalih njegovih strategija uz fiksirane strategije drugih igrača. Drugim riječima, u Nashovom ekvilibriju nijednom igraču se ne isplati promijeniti svoju strategiju ako zna strategije drugih igrača, odnosno nijedan igrač ne može **jednostrano** svojim potezom poboljšati ishod.

Konkretno za igru dva igrača možemo napisati da za Nashov ekvilibrij $a^* = (a_1^*, a_2^*)$ vrijedi:

$$u_1(a_1^*, a_2^*) \geq u_1(a_1, a_2^*), \quad \forall a_1 \in A_1,$$

$$u_2(a_1^*, a_2^*) \geq u_2(a_1^*, a_2), \quad \forall a_2 \in A_2.$$

S obzirom da je u Zatvorenikovoj dilemi svaki igrač imao samo dvije strategije na raspolaganju, u Nashovom ekvilibriju (P, P) za prvog igrača vrijedi $u_1(P, P) \geq u_1(N, P)$, tj. fiksirali smo strategiju P drugog igrača i uspoređivali korisnost prvog igrača *po stupcima* matrice, te istovremeno za drugog igrača imamo $u_2(P, P) \geq u_2(P, N)$, odnosno fiksirali smo strategiju P prvog igrača i uspoređivali korisnost drugog igrača *po retcima* matrice. Lako se provjeri da ostali strateški profili ne zadovoljavaju uvjete Nashovog ekvilibrija, primjerice ako fiksiramo strategiju N drugog igrača, za prvog igrača imamo $u_1(N, N) < u_1(P, N)$, odnosno prvom igraču se isplati promijeniti svoju strategiju iz N u P pa stoga (N, N) nije Nashov ekvilibrij.

Primijetimo da traženje Nashovog ekvilibrija u općenitim slučajevima s više igrača i puno strategija može biti dugotrajan i kompliciran postupak. S obzirom da za svakog igrača tražimo najbolji odgovor na fiksirane poteze drugih igrača, bit će korisno to formalno definirati. Za početak ćemo uvesti pojam korespondencije.

Definicija 1.4 Za neprazne skupove X i Y , preslikavanje $F : X \rightarrow Y$ koja svakom elementu iz skupa X pridružuje **podskup** od Y nazivamo **korespondencijom**.

Definicija 1.5 Korespondencija najboljeg odgovora (eng. best reply) igrača i je $BR_i : A_{-i} \rightarrow A_i$ s pravilom pridruživanja

$$BR_i(a_{-i}) = \{a_i \in A_i : u_i(a_{-i}, a_i) = \max_{a'_i \in A_i} u_i(a_{-i}, a'_i)\}.$$

Korespondencija najboljeg odgovora je $BR : A \rightarrow A$ s pravilom pridruživanja:

$$BR(a) = BR_1(a_{-1}) \times \cdots \times BR_n(a_{-n}).$$

Iz prethodne definicije je jasno da vrijedi sljedeće.

Propozicija 1.1 Strateški profil a^* je Nashov ekvilibrij ako i samo ako $a^* \in BR(a^*)$, odnosno $a_i^* \in BR_i(a_{-i}^*)$ za sve $i \in \{1, \dots, n\}$.

Dakle, naglasimo još jednom da je najbolji odgovor nekog igrača *skup strategija* koje daju najveću korisnost tom igraču uz fiksirane odgovore ostalih igrača, a strateški profil koji je u skupu najboljih odgovora svakog igrača bit će Nashov ekvilibrij. U primjeru Zatvorenikove dileme najbolji odgovor (u svakom promatranom slučaju) je priznati pa vrijedi $BR_1(N) = BR_1(P) = \{P\}$ i $BR_2(N) = BR_2(P) = \{P\}$, što se često označava zvjezdicom $*$ u matrici ishoda:

$$\begin{array}{cc} & \begin{array}{cc} N & P \end{array} \\ \begin{array}{c} N \\ P \end{array} & \begin{pmatrix} -1, -1 & -15, 0^* \\ 0^*, -15 & -10^*, -10^* \end{pmatrix} \end{array}$$

Prema Propoziciji 1.1 slijedi da je (P, P) Nashov ekvilibrij promatrane igre.

Kao što smo već komentirali, Nashov ekvilibrij ne mora dati kolektivno optimalno rješenje za igrače, a u sljedećim primjerima ćemo vidjeti da možemo imati i više Nashovih ekvilibrija, a Nashov ekvilibrij ne mora uopće ni postojati!

1.2 Klasični primjeri igara

■ **Primjer 1.2 — Bitka spolova (eng. battle of sexes).** U ovoj klasičnoj igri, muškarac i žena zasebno odlučuju (bez prethodnog dogovora) gdje će provesti večer: muškarac bi radije otišao na nogometnu utakmicu (N), žena na baletnu predstavu (B), no oboje bi bili sretniji ako zajedno provedu večer na istom mjestu. Njihove strategije i funkcije korisnosti dane su tablicom (retci predstavljaju strategije muškarca, a stupci strategije žene):

$$\begin{array}{cc} & \begin{array}{cc} N & B \end{array} \\ \begin{array}{c} N \\ B \end{array} & \begin{pmatrix} 10, 5 & 2, 2 \\ 0, 0 & 5, 10 \end{pmatrix} \end{array}$$

Traženjem najboljeg odgovora (veće korisnosti) za oba igrača, lako se provjeri da imamo dva Nashova ekvilibrija: (N, N) i (B, B) . U oba slučaja se nijednom igraču ne isplati promijeniti svoju odluku (uz fiksiranu odluku drugog igrača) jer će time imati manju korisnost. Za razliku od Zatvorenikove dileme, primijetimo da ovdje nema dominantne strategije nijednog igrača, te dodatno možemo reći da je ekvilibrij *nepravedan* u smislu da jedan igrač uvijek prolazi bolje od drugog.

■ **Primjer 1.3 — Igra koordinacije.** Dva lovca zasebno odlučuju hoće li krenuti u lov na jelena ili na zeca. Svatko može samostalno uloviti zeca (Z), no jelena (J) jedino mogu uloviti zajedno i tada podijeliti plijen. Pripadna tablica korisnosti je sljedeća:

$$\begin{array}{cc} & J & Z \\ \begin{array}{c} J \\ Z \end{array} & \begin{pmatrix} 3,3 & 0,1 \\ 1,0 & 1,1 \end{pmatrix} \end{array}$$

I u ovom slučaju imamo dva Nashova ekvilibrija: (J, J) i (Z, Z) . Za razliku od prethodnog primjera, ovdje je jasno da je optimalno rješenje koordiniran lov na jelena koji obojici daje najveću korisnost, no Nashov ekvilibrij nam ne daje informaciju koji strateški profil je bolji.

■ **Primjer 1.4 — Racionalne svinje.** Mala i velika svinja zajedno su smještene u toru, a hranu u korito dobivaju pritiskom sklopke koja se nalazi na drugom kraju tora. S obzirom da svinji treba neko vrijeme da otiđe s jednog kraja tora na drugi pretisnuti sklopu i vratiti se natrag, druga svinja može ostati čekati hranu kraj korita. Mala svinja brže trči po toru do sklopke, ali kada su obje svinje zajedno na koritu, velika svinja izgura malu koja tada ne može doći do hrane. Svaka svinja ima dvije strategije na raspolaganju: čekati (Č) kraj korita ili otići stisnuti sklopu (S). Njihova tablica korisnosti je sljedeća (retci su mala svinjica, a stupci velika):

$$\begin{array}{cc} & S & Č \\ \begin{array}{c} s \\ č \end{array} & \begin{pmatrix} 1,5 & -1,8 \\ 4,2 & 0,0 \end{pmatrix} \end{array}$$

Ovdje možemo primijetiti da mala svinja ima dominantnu strategiju: *čekati*. Naime, u obje strategije velike svinje, mala svinja bolje prolazi ako čeka (ne isplati joj se ići stisnuti sklopu). S obzirom da mala čeka, velikoj svinji jedino preostaje da otiđe stisnuti sklopu i doći do bar neke hrane, nego čekati i ostati gladna. Dakle imamo jedan Nashov ekvilibrij $(č, S)$, tj. mala svinja čeka kraj korita, a velika stišće sklopu. Provjerimo to i označavanjem najboljeg odgovora obiju svinja:

$$\begin{array}{cc} & S & Č \\ \begin{array}{c} s \\ č \end{array} & \begin{pmatrix} 1,5 & -1,8^* \\ 4^*, 2^* & 0^*, 0 \end{pmatrix} \end{array}$$

Eksperimenti su pokazali da se svinje doista tako ponašaju: već nakon par ponavljanja pokusa, mala svinja je shvatila da treba čekati, a velika da nema izbora nego otići stisnuti sklopu. Ovo je zgodan primjer igre u kojoj slabiji (pasivan) igrač bolje prolazi. ■

■ **Primjer 1.5 — Kamen, papir, škare.** Leo i Teo igraju poznatu igru kamen (K), papir (P), škare (Š): kamen pobjeđuje škare, škare pobjeđuju papir, papir pobjeđuje kamen. Ako pobjeda donosi 1 bod, a poraz -1 , tablica korisnosti je sljedeća:

$$\begin{array}{ccc} & K & P & Š \\ \begin{array}{c} K \\ P \\ Š \end{array} & \begin{pmatrix} 0,0 & -1,1 & 1,-1 \\ 1,-1 & 0,0 & -1,1 \\ -1,1 & 1,-1 & 0,0 \end{pmatrix} \end{array}$$

Uočimo da u svakom strateškom profilu neki od igrača može poboljšati svoj ishod promjenom odluke, odnosno nijedan strateški profil ne zadovoljava uvjete Nashovog ekvilibrija (nijedan nije u skupu najboljeg odgovora oba igrača). Ovo je klasičan primjer igre u kojoj ne postoji Nashov ekvilibrij, odnosno ne postoji potez koji bi igraču bio isplativiji u odnosu na druge. Naravno, ovo razmatranje vrijedi pod pretpostavkom da su svi potezi igrača jednako vjerojatni, no postavlja se pitanje: možemo li analizirati ovakve igre ukoliko znamo da drugi igrač preferira igrati kamen češće nego papir ili škare? Takvim modeliranjem igara ćemo se baviti u sljedećem poglavlju.

Vježba 1.1 Dva dizajnera se ne mogu usuglasiti oko izbora boja pri čemu jedan koristi RGB, a drugi HSV skalju. Imamo sljedeću tablicu korisnosti:

	<i>H</i>	<i>S</i>	<i>V</i>
<i>R</i>	2, 1	1, 4	2, 3
<i>G</i>	3, 3	1, 0	1, 5
<i>B</i>	1, 1	0, 2	2, 2

Nađite Nashov ekvilibrij.

Rješenje. $BR_1(H) = \{G\}$, $BR_1(S) = \{R, G\}$, $BR_1(V) = \{R, B\}$, $BR_2(R) = \{S\}$, $BR_2(G) = \{V\}$, $BR_2(B) = \{S, V\}$. Stoga imamo dva ekvilibrija (R, S) i (B, V) .

1.3 Primjeri iz ekonomije

Teorija igara od samih početaka ima veliku primjenu u ekonomiji. Mi ovdje nećemo ulaziti u detalje ekonomskih pojmova nego ćemo na par jednostavnih primjera objasniti glavne ideje i smjerove modeliranja u kojima teorija igara ima ulogu.

■ **Primjer 1.6 — Cournotov duopol.** Neki proizvod na tržištu nude dva proizvođača. Svaki proizvođač $i = 1, 2$ treba odabrati strategiju q_i koja označava količinu robe koju će proizvesti i plasirati na tržište. Neka je trošak proizvodnje jednog proizvoda jednak c (kod oba proizvođača), a cijena p po kojoj će se prodavati ovisi o zastupljenosti na tržištu te je određena zakonom ponude i potražnje. Radi jednostavnosti uzmimo linearni model $p = s - (q_1 + q_2)$, gdje je s najveća moguća cijena. Naravno, proizvođač neće poslovati s gubitkom pa je $q_1 + q_2 < s - c$ i $s > c$. Radi lakše analize pretpostavimo da se sva proizvedena roba proda te da mogu biti i necjelobrojne količine q_i . Nađite Nashov ekvilibrij.

Rješenje. Za svakog proizvođača funkcija korisnosti je $u_i(q_1, q_2) = (s - q_1 - q_2)q_i - cq_i = (s - q_1 - q_2 - c)q_i$, a za Nashov ekvilibrij $q^* = (q_1^*, q_2^*)$ mora vrijediti $u_1(q_1^*, q_2^*) \geq u_1(q_1, q_2^*)$, za sve q_1 , te analogno za sve q_2 .

Dakle, tražimo maksimum funkcije

$$f(q_1) = u_1(q_1, q_2) = -q_1^2 - q_1(s - c - q_2),$$

gdje je q_2 fiksno. To je kvadratna funkcija s tjemenom $q_1 = \frac{s-c-q_2}{2}$ pa je $BR_1(q_2) = \{\frac{s-c-q_2}{2}\}$. Analogno $BR_2(q_1) = \{\frac{s-c-q_1}{2}\}$.

Za Nashov ekvilibrij mora vrijedi

$$q_1^* = \frac{s - c - q_2^*}{2}, \quad q_2^* = \frac{s - c - q_1^*}{2},$$

a taj sustav ima (jedinstveno) rješenje $q_1^* = q_2^* = \frac{1}{3}(s - c)$. Tada je profit $u_1(q^*) = u_2(q^*) = \frac{1}{9}(s - c)^2$.

Primijeti da to nije optimalno rješenje jer bolje prolaze ako dogovore strategiju $q_i = \frac{1}{4}(s - c)$. Tada im je profit $u_i(q_i) = \frac{1}{8}(s - c)^2$ na uštrb veće cijene za kupce. Upravo zbog toga postoje državne agencije za zaštitu tržišnog natjecanja koje sprječavaju dogovore aktera na tržištu.

U slučaju monopola, funkcija korisnosti jedinog proizvođača je $u(q) = (s - c - q)q$ koja postiže max u $\frac{1}{2}(s - c)$, tj. profit proizvođača $u(q) = \frac{1}{4}(s - c)^2$, a cijena proizvoda je naravno veća nego kod duopola.

■ **Primjer 1.7 — Bertrandov duopol.** Ponovno imamo dva proizvođača koju nude isti proizvod na tržištu, no za razliku od Cournotovog modela gdje proizvođači donese odluku o količini (koja potom diktira cijenu), u ovom modelu proizvođači donose odluku o cijeni (koja diktira potražnju). Opet pretpostavljamo da je trošak proizvodnje jednog proizvoda jednak c , a cijene po kojima će proizvođači prodavati proizvod su $p_1, p_2 \geq c$. Potražnju modelirajmo sa

$$q(p_1, p_2) = s - \min(p_1, p_2),$$

gdje je s potražnja kada bi se proizvod dijelio besplatno (smisleno je da vrijedi $s > c$). Radi jednostavnosti ćemo pretpostaviti da tržište funkcionira po principu *pobjednik uzima sve* (svi će kupiti jeftiniji proizvod), a ako oboje ponude istu cijenu, svatko će dobiti pola kupaca. Nađite Nashov ekvilibrij. ■

Rješenje. : Funkciju korisnosti prvog igrača možemo zapisati kao

$$u_1(p_1, p_2) = \begin{cases} (p_1 - c)(s - p_1), & p_1 < p_2, \\ (p_1 - c)(s - p_1)/2, & p_1 = p_2, \\ 0, & p_1 > p_2, \end{cases}$$

te analogno i drugog igrača. Lako možemo vidjeti da je Nashov ekvilibrij (c, c) , odnosno da oba proizvođača posluju bez profita. Naime, ako drugi proizvođač fiksira cijenu p_2 , prvi proizvođač uvijek može *malo* spustiti cijenu ne bi li pridobio sve kupce i ostvario veći profit nego uz $p_1 = p_2$, i tako sve dok se ne spusti do $p_1 = c$. Isto razmišljanje ima i drugi proizvođač pa je zato jedini ekvilibrij (c, c) .

■ **Primjer 1.8 — Tragedija zajedničkog dobra (eng. tragedy of the commons).** U nekom selu sa n stočara svaki odlučuje koliko će krava posjedovati. Svi stočari vode svoje krave istovremeno na ispašu na obližnji zajednički pašnjak. Pretpostavimo da je trošak kupovine i brige oko jedne krave jednak c . Neka je $v(g)$ korist koju farmer ima od jedne krave ukoliko je ukupno g krava na pašnjaku. Koliko je ukupno krava u Nashovom ekvilibriju? ■

Rješenje. Realno je za očekivati da je $v(g)$ padajuća funkcija te da je njen pad sve strmiji kako ukupan broj krava raste. Naime, površina pašnjaka je konstantna pa čim je više krava, veće je natjecanje za zajednički resurs, odnosno korist od jedne krave je sve manja. U

skladu s time postoji neki $g_{\max}$ takav da je $v(g) = 0$, za sve $g \geq g_{\max}$. Nadalje, svaki stočar nastoji maksimizirati svoju funkciju korisnosti $u_i(a_1, \dots, a_n) = a_i v(a_1 + \dots + a_n) - c a_i$, gdje je a_i broj krava od stočara i .

Za Nashov ekvilibrij a^* vrijedi da je a_i^* stacionarna točka svake funkcije korisnosti, odnosno:

$$\frac{\partial u_i}{\partial a_i}(a_1^*, \dots, a_n^*) = v(a_1^* + \dots + a_n^*) + a_i^* v'(a_1^* + \dots + a_n^*) - c = 0.$$

Zbrajanjem ovih jednakosti za sve i i djeljenjem sa n dobivamo

$$v(g^*) + \frac{g^*}{n} v'(g^*) = c,$$

gdje je $g^* = a_1^* + \dots + a_n^*$ ukupan broj krava u ekvilibriju.

S druge strane, društveni cilj bi bio maksimizirati sveukupnu korisnost $gv(g) - cg$ čime dobijemo da je ukupan broj krava $\bar{g}$ za koji se postiže društveni maksimum:

$$v(\bar{g}) + \bar{g} v'(\bar{g}) = c.$$

Primijetimo da je $g^* > \bar{g}$, tj. ukupan broj krava u Nashovom ekvilibrijumu je veći od onog koji bi za društvo bio optimalan, odnosno dolazi do prekomjernog iskorištavanja resursa.



2. Mješovite strategije

2.1 Bimatrične igre

U Primjeru 1.5 smo se pitali možemo li drugačije modelirati traženje najboljeg odgovora igrača ukoliko znamo s kojom vjerojatnosti drugi igrač bira pojedini potez. Općenito u svakoj igri možemo imati znanja o vjerojatnostima odabira strategija te će nas zanimati možemo li u takvoj situaciji naći ekvilibrij. Za početak pogledajmo sljedeći jednostavni primjer.

■ **Primjer 2.1 — Par-nepar.** Ivica i Marica su pronašli kovanicu od 1 eura, ali se ne mogu dogovoriti tko će je zadržati. Odlučili su igrati par-nepar: prstima jedne ruke pokažu broj; ako je zbroj brojeva na prstima paran, kovanicu dobiva Ivica, a ako je neparan, dobiva Marica. ■

Pripadnu matricu ishoda možemo zapisati na sljedeći način gdje retci označavaju je li Ivica pokazao paran (P) ili neparan broj (N), a stupci predstavljaju Maricu:

$$\begin{array}{c} P \quad N \\ P \begin{pmatrix} 1,0 & 0,1 \end{pmatrix} \\ N \begin{pmatrix} 0,1 & 1,0 \end{pmatrix} \end{array}$$

Lako se može provjeriti da Nashov ekvilibrij ne postoji, u svakom strateškom profilu jedan od igrača može promijeniti svoj potez ne bi li poboljšao svoj ishod. No možemo li nešto reći oko ishoda igre ukoliko znamo s kojom vjerojatnosti će Ivica i Marica pokazati neki broj? Ako je veća vjerojatnost da će Marica odabrati paran broj, Ivici će tada biti isplativije također odabrati paran broj. No onda će Marica htjeti promijeniti svoju strategiju i odabrati neparan broj, odnosno uvijek će netko moći poboljšati svoj ishod. Intuitivno je jasno da će oboje biti u *vjerojatnosnoj ravnoteži* ukoliko nemaju preferencije, odnosno ako im je odabir svakog broja jednako vjerojatan. U tom slučaju je odabir parnog ili neparnog broja $\frac{1}{2}$, odnosno odabir svakog para strategija je $\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$ (uz pretpostavku nezavisnosti). Sada

se možemo zapitati koliki je *očekivani* ishod svakog strateškog profila:

$$\begin{array}{cc} & P & N \\ \begin{array}{c} P \\ N \end{array} & \begin{pmatrix} \frac{1}{4}, 0 \\ 0, \frac{1}{4} \end{pmatrix} & \begin{pmatrix} 0, \frac{1}{4} \\ \frac{1}{4}, 0 \end{pmatrix} \end{array}$$

Tada je ukupna očekivana korisnost Ivice $\frac{1}{4} + 0 + 0 + \frac{1}{4} = \frac{1}{2}$, a ista je i za Maricu $\frac{1}{2}$. Također primijeti da uz fiksiranu strategiju jednog igrača, očekivani ishod svakog poteza drugog igrača je $\frac{1}{4}$, odnosno igrač je indiferentan oko odabira svoje strategije. Možemo reći da su igrači u ravnoteži, odnosno navedeno stanje možemo doživjeti kao *vjerojatnosni* ekvilibrij.

Ukoliko vjerojatnosnu distribuciju odabira strategija svakog igrača zapišemo u matricnom obliku $\begin{bmatrix} \frac{1}{2} & \frac{1}{2} \end{bmatrix}$, primijeti da računanje očekivane korisnosti možemo zapisati kao umnožak matrica, npr. za Ivicu imamo:

$$\begin{bmatrix} \frac{1}{2} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix} = \frac{1}{2}$$

Sve navedeno nas motivira da uvedemo sljedeće definicije.

Definicija 2.1 Mješovito proširenje strateške igre (A, u) je strateška igra (S, u) takva da za svaki $i \in \{1, \dots, n\}$ imamo:

- $S_i = \Delta A_i$ skup mješovitih strategija igrača i , gdje je

$$\Delta A_i = \{x \in [0, 1]^{A_i} : \sum_{a_i \in A_i} x(a_i) = 1\}.$$

Neka je $S = S_1 \times \dots \times S_n$, a za $s \in S$ i $a \in A$ neka je $s(a) = s_1(a_1) \dots s_n(a_n)$ proizvoljni mješoviti strateški profil.

- $u_i : S \rightarrow \mathbb{R}$ proširena funkcija korisnosti igrača i definirana s

$$u_i(s) = \sum_{a \in A} u_i(a) s(a).$$

Mješovite strategije S_i su zapravo **vjerojatnosne distribucije** preko kojih igrač i bira strategije iz A_i . Tada je $s(a)$ vjerojatnost da se svi (nezavisni) igrači odluče za strateški profil a , a $u_i(s)$ je naravno očekivana korisnost igrača i u profilu s .

Ako igrač ne bira strategije na slučajan način nego se odlučuje za jednu fiksnu strategiju s vjerojatnosti 1 (a za ostale je vjerojatnost 0), dobivamo originalne strategije iz strateške igre (A, u) koje još nazivamo **čistim strategijama**. Dakle, čiste strategije su podskup mješovitih strategija.

Sada možemo predstaviti temeljni teorem teorije igara o egzistenciji Nashovog ekvilibrija.

Teorem 2.1 — Nash. Mješovito proširenje (S, u) konačne strateške igre (A, u) ima barem jedan Nashov ekvilibrij.

Prema tome, kod mješovitih strateških igara ekvilibrij će uvijek postojati! Pritom treba imati na umu da on ne mora biti čisti, odnosno kao što smo vidjeli u Primjeru 2.1, postoje strateške igre bez čistog ekvilibrija.

Dokaz teorema je Nash predstavio u svojoj doktorskoj disertaciji, no mi ga na ovom mjestu izostavljamo jer zahtjeva dodatna znanja iz naprednije matematičke analize i topologije.

Mi ćemo se u nastavku baviti samo igrama s dva igrača pa uvodimo sljedeći pojam.

Definicija 2.2 Bimatrična igra je mješovito proširenje konačne igre s dva igrača. ■

Označimo sa $U^{(1)} = (u_1(i, j))$ i $U^{(2)} = (u_2(i, j))$ matrice korisnosti svakog igrača, koje zajedno daju standardne bimatrice korisnosti koje smo proučavali do sada. Mješovite strategije $x \in S_1$ i $y \in S_2$ ćemo doživljavati kao vektor redak s vjerojatnosnom distribucijom $[p_1 \ p_2 \ \dots \ p_n]$, $\sum p_i = 1$, pa za proširene funkcije korisnosti možemo pisati:

$$u_1(x, y) = \sum_{i,j} u_1(i, j) x_i y_j = \vec{x} U^{(1)} \vec{y}^T,$$

$$u_2(x, y) = \sum_{i,j} u_2(i, j) x_i y_j = \vec{x} U^{(2)} \vec{y}^T.$$

Za bimatričnu igru 2×2 (kada svaki igrač ima na raspolaganju samo 2 strategije), radi jednostavnosti pišemo da vektor mješovitih strategija $\vec{x}$ ima razdiobu vjerojatnosti $(x, 1-x)$, $x \in [0, 1]$.

Za početak ćemo riješiti mješovite varijante dviju klasičnih igara iz prethodnog potpoglavlja.

■ **Primjer 2.2 — Mješovita "bitka spolova".** Lolek i Bolek odlučuju kako će provesti subotu. Lolek želi u Hrvatsko narodno kazalište (HNK), a Bolek u kino, no svakako im je draže da vrijeme provedu zajedno. Nađite sve mješovite Nashove ekvilibrije ako je korisnost dana bimatricom:

$$\begin{array}{cc} & \begin{array}{cc} HNK & Kino \end{array} \\ \begin{array}{c} HNK \\ Kino \end{array} & \left(\begin{array}{cc} 6, 3 & 1, 1 \\ 0, 0 & 3, 6 \end{array} \right) \end{array}$$

■

Rješenje. Da bismo pronašli Nashove ekvilibrije, prvo ćemo odrediti najbolje odgovore prvog i drugog igrača. Krenimo od Loleka, odnosno tražimo BR_1 uz fiksiranu strategiju $\vec{y}$. Računamo njegovu proširenu korisnost:

$$\vec{x} U^{(1)} \vec{y}^T = [x \ 1-x] \begin{bmatrix} 6 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} y \\ 1-y \end{bmatrix} = x(8y-2) + 3 - 3y.$$

Sada tražimo gdje ta funkcija u varijabli x postiže maksimum (ovisno o y). S obzirom da se radi o linearnoj funkciji, dovoljno je promatrati koeficijent uz x . Ako je $y < \frac{1}{4}$, funkcija je padajuća pa se njena maksimalna vrijednost postiže za $x = 0$, a za $y > \frac{1}{4}$ je rastuća pa je maksimalna vrijednost u desnom rubu $x = 1$. U graničnom slučaju $y = \frac{1}{4}$

funkcija je konstantna pa postiže istu (maksimalnu) vrijednost za sve $x \in [0, 1]$). Odnosno, ukoliko drugi igrač odabere strategiju $\vec{y} = (\frac{1}{4}, \frac{3}{4})$, prvi igrač ne može promijeniti svoju očekivanu korisnost, ona je uvijek ista za sve njegove strategije $\vec{x}$. Prethodnu analizu zapisujemo na sljedeći način:

$$BR_1(y) = \begin{cases} \{0\}, & y \in [0, \frac{1}{4}) \\ [0, 1], & y = \frac{1}{4} \\ \{1\}, & y \in (\frac{1}{4}, 1]. \end{cases}$$


Koristeći ishode drugog igrača, računamo njegovu proširenu korisnost u varijabli y uz fiksni x :

$$\vec{x}U^{(2)}\vec{y}^T = [x \quad 1-x] \begin{bmatrix} 3 & 1 \\ 0 & 6 \end{bmatrix} \begin{bmatrix} y \\ 1-y \end{bmatrix} = y(8x-6) + 6 - 5x.$$

Sličnom analizom kao za prvog igrača, dobivamo da je njegov najbolji odgovor:

$$BR_2(x) = \begin{cases} \{0\}, & x \in [0, \frac{3}{4}) \\ [0, 1], & x = \frac{3}{4} \\ \{1\}, & x \in (\frac{3}{4}, 1]. \end{cases}$$

Nashovi ekvilibriji (x^*, y^*) su strateški profili koji se nalaze u najboljem odgovoru oba igrača, odnosno predstavljaju presjeka dobivenih korespondencija najboljeg odgovora, a najlakše se očitaju grafički, vidi Sliku 2.1.



Slika 2.1: Primjer 2.2

Uočavamo tri točke presjeka, odnosno tri Nashova ekvilibrija, a pripadne strategije zapisujemo na sljedeći način: $((0, 1), (0, 1))$, $((\frac{3}{4}, \frac{1}{4}), (\frac{1}{4}, \frac{3}{4}))$ i $((1, 0), (1, 0))$. Primijeti da su prvi i treći ekvilibrij čiste strategije (Kino-Kino i HNK-HNK) koje smo već komentirali u čistoj strateškoj igri bitke spolova. Drugi (mješoviti) ekvilibrij predstavlja strateški profil u kojem Lolek odabire HNK s vjerojatnosti $\frac{3}{4}$ (kino s $\frac{1}{4}$), a Bolek HNK s vjerojatnosti $\frac{1}{4}$ (kino s $\frac{3}{4}$). Podsjetimo se da su u analizi najboljeg odgovora to bili slučajevi kada fiksiranjem strategije jednog igrača, drugi igrač ne može poboljšati svoju korisnost nijednom strategijom, odnosno korisnost mu je uvijek ista. Također primijetimo da za razliku od čistih ekvilibrija u kojem uvijek jedan od igrača bolje prolazi u odnosu na drugog, mješoviti ekvilibrij je pravedan u smislu da oba igrača imaju istu (očekivanu) korisnost, koja u ovom slučaju iznosi $u_1 = u_2 = \frac{9}{4}$.

■ **Primjer 2.3 — Mješovita Zatvorenikova dilema.** Podsjetimo se Tomice i Perice iz Primjera 1.1 koji su na policijskom ispitivanju nakon pljačke banke:

$$\begin{array}{cc} & \begin{array}{cc} N & P \end{array} \\ \begin{array}{c} N \\ P \end{array} & \begin{pmatrix} -1, -1 & -15, 0 \\ 0, -15 & -10, -10 \end{pmatrix} \end{array}$$

Pronađite sve mješovite ekvilibrije.

Rješenje. Proširena korisnost Tomice (uz fiksiranu strategiju $\vec{y}$) je

$$\vec{x}U^{(1)}\vec{y}^T = [x \quad 1-x] \begin{bmatrix} -1 & -15 \\ 0 & -10 \end{bmatrix} \begin{bmatrix} y \\ 1-y \end{bmatrix} = x(4y-5) + 10y - 10.$$

Primijeti da je dobivena linearna funkcija uvijek padajuća (jer je $y \in [0, 1]$) pa slijedida je njen maksimum uvijek u lijevom rubu, odnosno imamo $BR_1(y) = \{0\}$, $y \in [0, 1]$. Na sličan način se i za Pericu dobije $BR_2(x) = \{0\}$, $x \in [0, 1]$. Stoga je jedina točka presjeka $((0, 1), (0, 1))$, odnosno imamo samo čisti ekvilibrij (P, P) , a nemamo mješovitih ekvilibrija.

■

Sada pogledajmo primjere bimatričnih igara u kojem igrači imaju na raspolaganju više od 2 poteza. Kod takvih većih bimatrica, ideja je eliminirati retke i stupce s nedominantnim strategijama sve dok ne smanjimo dimenziju problema do matrice 2×2 . Glavna ideja je sljedeća: ako neka mješovita strategija dominira, odnosno daje veću korisnost (za svaki odabir poteza) nego neka čista strategija, onda takva (slabija) čista strategija ne može biti dio Nashovog ekvilibrija jer inače bi igrač mogao napraviti potez koji bi mu donio veću korisnost. Formalna definicija (stroge) dominacije je u nastavku.

Definicija 2.3 Mješovita strategija $\vec{x}$ prvog igrača **strogo dominira** i -tu čistu strategiju ako je $\vec{x}U^{(1)} > u_i^{(1)}$ (po elementima) te analogno, mješovita strategija $\vec{y}$ drugog igrača **strogo dominira** j -tu čistu strategiju ako je $U^{(2)}\vec{y}^T > u_j^{(2)}$ (po elementima). ■

Na sljedećem primjeru ćemo vidjeti konkretne stroge dominacije nad nekim retkom ili stupcem.

■ **Primjer 2.4** Nađite Nashov ekvilibrij mješovite bimatrične igre:

$$\begin{array}{cc} & \begin{array}{cccc} \alpha & \beta & \gamma & \delta \end{array} \\ \begin{array}{c} A \\ B \\ C \end{array} & \begin{pmatrix} 2, 2 & 2, 1 & 2, 2 & 0, 0 \\ 1, 0 & 4, 1 & 2, 4 & 1, 5 \\ 0, 4 & 3, 1 & 3, 0 & 3, 3 \end{pmatrix} \end{array}$$

Rješenje. Prvo primijetimo da u matrici nema stroge dominacije nijedne čiste strategije po retcima ni po stupcima pa ćemo pokušati naći neku mješovitu.

Primjerice, strategija drugog igrača $(p, 0, 1-p, 0) = p\alpha + (1-p)\gamma$ strogo dominira strategiju β uz uvjete $2p + 2(1-p) > 1$, $4(1-p) > 1$, $4p > 1$, odnosno za neki $\frac{1}{4} < p < \frac{3}{4}$. Dakle, postoji mješovita strategija koja po elementima daje strogo veću korisnost nego stupac β pa ga možemo maknuti i nastaviti s matricom 3×3 :

$$\begin{array}{ccc} & \alpha & \gamma & \delta \\ A & (2,2) & (2,2) & (0,0) \\ B & (1,0) & (2,4) & (1,5) \\ C & (0,4) & (3,0) & (3,3) \end{array}$$

Opet nema čistih dominacija, ali npr. strategija prvog igrača $(q, 0, 1 - q) = qA + (1 - q)C$ će strogo dominirati redak B za $2q > 1$, $2q + 3(1 - q) > 2$ i $3(1 - q) > 1$. Stoga možemo maknuti strategiju B za $\frac{1}{2} < q < \frac{2}{3}$ te nam ostaje matrica:

$$\begin{array}{ccc} & \alpha & \gamma & \delta \\ A & (2,2) & (2,2) & (0,0) \\ C & (0,4) & (3,0) & (3,3) \end{array}$$

Sada odmah primijećujemo da čista strategija α dominira nad δ pa eliminiramo treći stupac:

$$\begin{array}{cc} & \alpha & \gamma \\ A & (2,2) & (2,2) \\ C & (0,4) & (3,0) \end{array}$$


Dobivenu matricu 2×2 riješimo grafički tražeći presjeke korespondencija najboljeg odgovora kao i prije. Za prvog igrača imamo:

$$\vec{x}U^{(1)}\vec{y}^T = x(3y - 1) + 3 - 3y \Rightarrow BR_1(y) = \begin{cases} \{0\}, & y \in [0, \frac{1}{3}), \\ [0, 1], & y = \frac{1}{3}, \\ \{1\}, & y \in (\frac{1}{3}, 1], \end{cases}$$

a za drugog igrača vrijedi:

$$\vec{x}U^{(2)}\vec{y}^T = y(4 - 4x) + 2x \Rightarrow BR_2(x) = \begin{cases} \{1\}, & x \in [0, 1), \\ [0, 1], & x = 1. \end{cases}$$

Prikažimo to grafički:



Sa slike vidimo da su u presjeku sve točke $y \in [\frac{1}{3}, 1]$ za $x = 1$, odnosno imamo beskonačno Nashovih ekvilibrija. Za konačni zapis ekvilibrija početne bimatrične igre, potrebno je još staviti nule na mjesta izbačenih redaka/stupaca pa dobivamo sljedeći skup strategija kao konačno rješenje:

$$(x^*, y^*) = ((1, 0, 0), (y, 0, 1 - y, 0)), \quad y \in [\frac{1}{3}, 1].$$

Uočimo još da rješenje $y = 1$ daje Nashov ekvilibrij (A, α) čiste strateške igre. ■

Nameće se pitanje kako tražiti Nashove ekvilibrije u većim igrama u kojima ne možemo naći dominantne strategije. Postoje razni algoritmi koji uspješno traže ekvilibrije, no imaju veliku računalnu složenost, štoviše eksponencijalnu s porastom broja akcija i igrača. Zbog toga se ovo područje u kontekstu računarstva i dalje intenzivno istražuje te je još uvijek otvoreno pitanje postoji li algoritam koji nalazi Nashove ekvilibrije u polinomijalnom vremenu, čak i za bimatrične igre sa samo dva igrača!

Vježba 2.1 — MI-2023. Pri upisu godine na Fakultetu računarstva i informacijskih tehnologija (FRIT) Ivica i Perica se dvoume između izbornih predmeta. Ivica više preferira Teoriju odlučivanja, a Perica Teoriju igara, no bili bi sretniji da zajedno slušaju isti predmet. Ako upisuju predmete bez prethodnog dogovora, korisnosti odabira su u sljedećoj bimatrici:

$$\begin{array}{cc} & TI & TO \\ TI & (7, 10) & (0, 0) \\ TO & (3, 3) & (10, 7) \end{array}$$

Odredite sve čiste i mješovite Nashove ekvilibrije njihovih odabira predmeta.

Vježba 2.2 — MI-2024. Mace Leo i Teo biraju što će jesti za večeru. Leo bira brand hrane, odnosno hoće li jesti *Happy Kitty* (H) ili *Kitty Love* (K), dok Teo odabire vrstu mesa: piletinu (P), teletinu (T) ili ribu (R). Ako su korisnosti njihovih odabira dane u sljedećoj bimatrici, odredite sve čiste i mješovite Nashove ekvilibrije:

$$\begin{array}{ccc} & P & T & R \\ H & (3, 1) & (3, 2) & (5, 6) \\ K & (3, 5) & (1, 4) & (8, 3) \end{array}$$

2.2 Korelirane strategije i korelirani Nashov ekvilibrij

Već smo primijetili da Nashov ekvilibrij ne mora dati optimalno rješenje, odnosno postoje strategije u kojima će igrači ostvariti veću korist nego u ekvilibriju. U tu svrhu pogledajmo sljedeću poznatu igru "hrabrosti".

■ **Primjer 2.5 — igra kukavice, eng. chicken game.** Na raskrižje bez semafora dolaze dva automobila iz okomitih smjerova te svaki od vozača treba odlučiti hoće li projuriti kroz raskrižje (J) ili se zaustaviti (Z) i propustiti drugog vozača. Neka je bimatrica korisnosti:

$$\begin{array}{cc} & P & Z \\ P & (-6, -6) & (2, -1) \\ Z & (-1, 2) & (0, 0) \end{array}$$

Ukoliko oba vozača projure, sudarit će se i oba imati negativnu korisnost, a ukoliko jedan projuri, a drugi se zaustavi, prvi će biti pobjednik, a drugi će ispasti kukavica otkud i dolazi ime igre. ■

Lako se provjeri da imamo dva Nashova ekvilibrija s čistim strategijama (J, Z) i (Z, J) (u oba jedan igrač prolazi bolje, odnosno nisu poštteni prema "kukavici") te jedan ekvilibrij s mješovitim strategijama $((\frac{2}{7}, \frac{5}{7}), (\frac{2}{7}, \frac{5}{7}))$. Mješovitom ekvilibriju možemo

dodijeliti vjerojatnosnu distribuciju svih strateških profila u obliku matrice:

$$\begin{bmatrix} \frac{4}{49} & \frac{10}{49} \\ \frac{10}{49} & \frac{25}{49} \end{bmatrix}$$

Tada je očekivana korisnost svakog igrača jednaka $u_1 = u_2 = -\frac{2}{7}$, ali negativna.

Pretpostavimo sada da je na raskrižje postavljen semafor koji s jednakom vjerojatnosti propušta jedan ili drugi smjer te da će vozači poštovati semafor. Tada imamo vjerojatnosnu distribuciju strateških profila:

$$P = \begin{bmatrix} 0 & \frac{1}{2} \\ \frac{1}{2} & 0 \end{bmatrix}$$

U ovom slučaju je očekivana korisnost svakog igrača $u_1 = u_2 = \frac{1}{2}$, tj. veća nego u Nashovom ekvilibriju.

Primijeti da ne postoji mješovita strategija koja daje ovakvu distribuciju: ako je vjerojatnost nula da igrači odigraju profil (J, J) , onda je vjerojatnost odabira strategije J barem jednog od igrača jednaka nuli, no tada ne može vjerojatnost profila (J, Z) ili (Z, J) biti $\frac{1}{2}$. No lako je zamisliti da je takav ishod u igri ipak moguć, odnosno da je vjerojatnost 50% da će se ili jedan ili drugi vozač zaustaviti. Stoga ćemo za takve strategije uvesti novi naziv.

Definicija 2.4 Strategije kojima je pridružena vjerojatnosna distribucija $P = (p_{ij})$ na skupu strateških profila, odnosno stohastička matrica s elementima $p_{ij} \in [0, 1]$ i sa sumom 1, zovemo **koreliranim strategijama**. ■

Također možemo definirati i pripadni ekvilibrij.

Definicija 2.5 Korelirani ekvilibrij bimatrične igre je korelirana strategija $P = (p_{ij})$ za koju vrijedi

$$\begin{aligned} \sum_{j \in A_2} p_{ij}(u_{ij}^{(1)} - u_{kj}^{(1)}) &\geq 0, \quad \forall i, k \in A_1, \\ \sum_{i \in A_1} p_{ij}(u_{ij}^{(2)} - u_{il}^{(2)}) &\geq 0, \quad \forall j, l \in A_2. \end{aligned}$$

Očito su mješovite strategije u Nashovom ekvilibriju korelirane, tj. možemo im pridružiti stohastičku matricu P . No može se pokazati i više od toga, da su one nužno i korelirani ekvilibrij. No obrat naravno ne vrijedi, nije svaki korelirani ekvilibrij Nashov.

Propozicija 2.1 Neka je (x^*, y^*) Nashov ekvilibrij bimatrične igre. Tada je on i jedan od koreliranih ekvilibrija te igre.

Kao što smo već spomenuli, traženje Nashovih ekvilibrija je općenito računalno složen problem. No traženje koreliranih ekvilibrija je programski manje zahtjevnije jer se svodi na linearno programiranje pa je u tome njihov značaj. Za prethodni primjer iz uvjeta koreliranog ekvilibrija dobivamo sustav nejednadžbi:

$$\begin{aligned} -5p_{11} + 2p_{12} &\geq 0, & 5p_{21} - 2p_{22} &\geq 0, \\ -5p_{11} + 2p_{21} &\geq 0, & 5p_{12} - 2p_{22} &\geq 0. \end{aligned} \tag{2.1}$$

Zajedno uz vjerojatnosne uvjete $p_{ij} \in [0, 1]$ te $\sum p_{ij} = 1$, možemo odrediti sva moguća rješenja. U ovom slučaju imamo beskonačno koreliranih ekvilibrija koji geometrijski tvore konveksan poliedar u prostoru vjerojatnosti. Lako se provjeri da Nashovi ekvilibriji zadovoljavaju nejednadžbe (2.1), kao i već spomenuta distribucija

$$P_1 = \begin{bmatrix} 0 & \frac{1}{2} \\ \frac{1}{2} & 0 \end{bmatrix}.$$

Osim njih, neki drugi korelirani ekvilibriji su primjerice

$$P_2 = \begin{bmatrix} \frac{1}{6} & \frac{5}{12} \\ \frac{5}{12} & 0 \end{bmatrix}, \quad P_3 = \begin{bmatrix} \frac{1}{7} & \frac{5}{14} \\ \frac{5}{14} & \frac{1}{7} \end{bmatrix}$$

Za svaki pojedini slučaj se može izračunati očekivani ishod pa među njima naći bolja rješenja za igrače. Tu se upravo ističe distribucija P_1 jer daje najbolji ishod u smislu pravednosti (oba igrača imaju istu očekivanu korisnost) i pozitivosti (kod mješovitog Nashovog ekvilibrija korisnost igrača je jednaka, ali negativna).

2.3 Simetrične igre i simetričan Nashov ekvilibrij

U prethodnim primjerima smo vidjeli da u nekim igrama igrači imaju isti skup strategija te *simetrične* ishode u tablicama korisnosti. U ovom potpoglavlju ćemo dodatno proučiti takve igre koje su česte u primjeni.

Definicija 2.6 Bimatrična igra je **simetrična** ako oba igrača imaju isti skup strategija te ako je $U^{(1)} = (U^{(2)})^T$. ■

Strateški profili u kojima igrači imaju istu (mješovitu) strategiju, nazivamo simetričnim profilima. Stoga u igrama može postojati i simetričan ekvilibrij. Upravo se uz simetrične igre i egzistenciju simetričnog ekvilibrija veže drugi rezultat koji je Nash dokazao u svojoj disertaciji.

Propozicija 2.2 Svaka simetrična bimatrična igra ima simetričan Nashov ekvilibrij.

Primjeri simetričnih igra koje smo do sada promatrali su bila igra kukavice i zatvorenikova dilema. Igra kukavice ima dva nesimetrična čista ekvilibrija $((0, 1), (1, 0))$ i $((1, 0), (0, 1))$, no dobili smo i jedan mješoviti ekvilibrij $((\frac{2}{7}, \frac{5}{7}), (\frac{2}{7}, \frac{5}{7}))$ koji je evidentno simetričan. Zatvorenikova dilema ima samo jedan (čisti) simetrični ekvilibrij $((0, 1), (0, 1))$.

Pritom treba biti na oprezu da npr. bitka spolova nije simetrična igra bez obzira što igrači imaju isti skup strategija i iste korisnosti. Naime, za tu igru ne vrijedi da je matrica korisnosti prvog igrača transponirana matrica drugog igrača, odnosno nedostaje svojstvo simetričnosti. Unatoč tome, u toj igri iz Primjera 2.2 smo dobili dva čista simetrična ekvilibrija $((0, 1), (0, 1))$ i $((1, 0), (1, 0))$, no mješoviti ekvilibrij $((\frac{3}{4}, \frac{1}{4}), (\frac{1}{4}, \frac{3}{4}))$ nije simetričan.

Pogledajmo još jedan standardni primjer iz teorije igara koji je sličan bitci spolova, no u simetričnoj varijanti.

■ **Primjer 2.6 — jastreb-golub eng. hawk-dove**. Dvije životinje trebaju podijeliti plijen i mogu se pritom ponašati agresivno (A) ili pasivno (P). Ako se obje životinje

agresivne, napast će jedna drugu i ostati bez plijena. U pasivnom stanju će podijeliti plijen, a u ostalim slučajevima će agresivna životinja uzeti veći dio plijena. Navedeno ćemo zapisati u sljedeću bimatricu korisnosti:

$$\begin{array}{cc} & \begin{array}{c} A \quad P \end{array} \\ \begin{array}{c} A \\ P \end{array} & \begin{pmatrix} 0,0 & 5,1 \\ 1,5 & 3,3 \end{pmatrix} \end{array}$$

S obzirom da se radi o simetričnoj igri, sami provjerite da postoji jedan mješoviti simetrični ekvilibrij $((\frac{2}{3}, \frac{1}{3}), (\frac{2}{3}, \frac{1}{3}))$. Ostala dva ekvilibrija su čisti nesimetrični (A, P) i (P, A) . ■

Prethodni primjer je zanimljiv jer ako pretpostavimo da je agresivno ili pasivno ponašanje neke jedinke urođeno, mješovitu strategiju možemo doživjeti kao postotak agresivnih i pasivnih jedinki u populaciji. Odnosno, u ravnotežnom stanju populacije, dvije trećine jedinki će se ponašati agresivno, a jedna trećina pasivno. Takvo razmišljanje otvara vrata prema jednom sasvim novom dijelu teorija igara koji se naziva **evolucijska** teorija igara. Napraviti ćemo kratki uvod u tu teoriju.

Definicija 2.7 Mješovita strategija $\vec{x}$ je evolucijski stabilna strategija ako za svaku mješovitu strategiju $\vec{y} \neq \vec{x}$ postoji $\varepsilon_y \in (0, 1)$ takav za da sve $\varepsilon \in (0, \varepsilon_y)$ vrijedi

$$\vec{x}U(\varepsilon\vec{y} + (1 - \varepsilon)\vec{x})^T > \vec{y}U(\varepsilon\vec{y} + (1 - \varepsilon)\vec{x})^T.$$

Drugim riječima, populacija s razdiobom $\vec{x}$ je evolucijski stabilna ako nakon miješanja s nekom populacijom $\vec{y}$ (u omjeru $\varepsilon\vec{y} + (1 - \varepsilon)\vec{x}$) i dalje prevagne originalna populacija (tj. za svaki takav ε razdioba $\vec{x}$ daje bolji odgovor od novih jedinki iz $\vec{y}$). Sljedeći teorem nam daje nužne i dovoljne uvjete da bi strategija bila evolucijski stabilna, odnosno pokazuje usku povezanost evolucijske stabilnosti i (simetričnog) Nashovog ekvilibrija.

Teorem 2.2 Mješovita strategija $\vec{x}$ je evolucijski stabilna strategija ako i samo ako je $\vec{x}$ simetrični Nashov ekvilibrij i vrijedi

$$\vec{x}U\vec{y}^T > \vec{y}U\vec{y}^T$$

za sve mješovite strategije $\vec{y} \neq \vec{x}$ za koje je $\vec{x}U\vec{x}^T = \vec{y}U\vec{x}^T$.

Provjerimo evolucijsku stabilnost na primjeru igre jastreb-golub. Već smo vidjeli da je $\vec{x} = (\frac{2}{3}, \frac{1}{3})$ jedini simetrični Nashov ekvilibrij pa je prema prethodnom teoremu to i jedini kandidat za evolucijski stabilnu strategiju.

Nađimo sada $\vec{y} = (y, 1 - y)$ takve da je $\vec{x}U\vec{x}^T = \vec{y}U\vec{x}^T$. Računom se dobije

$$\frac{5}{3} = \frac{5}{3}(y + 1 - y) = \frac{5}{3},$$

odnosno to vrijedi za sve y . Sada treba provjeriti nejednakost $\vec{x}U\vec{y}^T > \vec{y}U\vec{y}^T$ za sve $\vec{x} \neq \vec{y}$. Imamo sljedeće:

$$\vec{x}U\vec{y}^T - \vec{y}U\vec{y}^T = (\frac{13}{3} - 4y) - 3(1 - y^2) = \frac{1}{3}(3y - 2)^2 > 0.$$

S obzirom da dobivena nejednakost vrijedi za sve $y \neq \frac{2}{3}$, po teoremu slijedi da je $\bar{x}$ evolucijski stabilna strategija.

Za kraj napomenimo da je evolucijska teorija igara izvorno imala primjenu u biologiji (npr. ponašanje populacija životinja, modeliranje širenja mutacija virusa), no danas ima primjene i u sociologiji, ekonomiji, te u zadnje vrijeme sve veću primjenu u računarstvu i razvoju evolucijskih algoritama (genetski algoritmi, neuronske mreže i sl.) .



3. Igre sume-nula

U svakodnevnom životu često susrećemo konfliktne situacije u kojima je ishod "pobjeda" ili "poraz", odnosno dobitak jednog igrača je jednak gubitku drugog. Takav slučaj smo promatrali u Primjeru 1.5 (kamen, papir, škare) u kojem smo vidjeli da je u svakom strateškom profilu suma dobitaka i gubitaka uvijek nula, odnosno nema mogućnosti obostrane koristi ili bilo kakvog kompromisa. Svaki igrač nastoji maksimizirati vlastitu dobit, istovremeno minimizirajući dobit protivnika, pa analizom takve igre doći ćemo do važnog pojma *minimax rješenja*, koje označava optimalnu strategiju u najnepovoljnijem scenariju. Ovakve igre modeliraju situacije sukoba interesa, poput tržišnih nadmetanja, sportskih natjecanja ili vojnih strategije te čine temelj za razvoj složenijih modela u teoriji igara i ekonomiji odlučivanja.

3.1 Vrijednost igre sume-nula

Za jednostavni uvodni primjer pogledajmo klasičnu igru bacanja novčića.

■ **Primjer 3.1 — Pismo-glava (eng. matching pennies).** Dva igrača bacaju po jedan novčić. Ukoliko na oba novčića padne isti znak (pismo-pismo ili glava-glava), pobjeđuje prvi igrač, a ako padne različit znak na novčićima, pobjeđuje drugi igrač. Pripadna tablica korisnosti je:

$$\begin{array}{cc} & \begin{array}{cc} P & G \end{array} \\ \begin{array}{c} P \\ G \end{array} & \begin{pmatrix} 1, -1 & -1, 1 \\ -1, 1 & 1, -1 \end{pmatrix} \end{array}$$

Lako se provjeri da čisti Nashov ekvilibrij ne postoji, a mješoviti je $(\frac{1}{2}, \frac{1}{2})$ s očitom očekivanom korisnosti oba igrača $u = 0$. ■

Slično kao u Primjeru 1.5, u svakom strateškom profilu suma ishoda oba igrača je uvijek nula, pa otud i slijedi naziv za takav tip igre.

Definicija 3.1 — eng. sum-zero game. Igra sume-nula s n igrača je strateška igra (A, u) takva da za svaki strateški profil $a \in A$ vrijedi $u_1(a) + \dots + u_n(a) = 0$. ■

Ukoliko imamo dva igrača dovoljno nam je samo poznavati funkciju korisnosti jednog igrača u_1 jer odmah slijedi da je korisnost drugog igrača $u_2 = -u_1$, kao što je bio slučaj u primjerima 1.5 i 3.1. Stoga ćemo takve igre analizirati koristeći samo jednu matricu $U^{(1)}$.

Pogledajmo sada primjer igre *pucanja penala* iz teorije sporta.

■ **Primjer 3.2 — eng. penalty kick game.** Nogometaš izvodi penal odabirom pucanja na lijevu ili desnu stranu gola, pri čemu bolje pogađa lijevu stranu. Golman također bira hoće li skočiti lijevo ili desno, te ako odabere istu stranu na koju strijelac puca, pretpostavimo (radi jednostavnosti modela) da sigurno brani. Neka je dana tablica korisnosti strijelca:

$$\begin{array}{cc} & \begin{array}{cc} L & D \end{array} \\ \begin{array}{c} L \\ D \end{array} & \begin{pmatrix} 0 & 3 \\ 2 & 0 \end{pmatrix} \end{array}$$

Dakle, strijelac ima veću korisnost odabirom lijeve strane jer pogađa gol sa većom sigurnosti. Korisnost golmana je ista, ali sa suprotnim predznakom. Ponovno se lako vidi da ne postoji čisti Nashov ekvilibrij, a mješoviti je $(\frac{2}{5}, \frac{3}{5})$ za strijelca, odnosno u ekvilibriju je vjerojatnost da će gađati svoju slabiju stranu. Za golmana je ekvilibrij $(\frac{3}{5}, \frac{2}{5})$, odnosno veća je vjerojatnost da će skočiti na bolju stranu strijelca. To možemo protumačiti na način da oba igrača pokušavaju optimizirati svoj ishod u nepovoljnijoj situaciji. Statističkom analizom su istraživanja pokazala da se profesionalni nogometaši doista tako ponašaju, odnosno veća je vjerojatnost da će strijelac pucati na svoju lošiju stranu, a golman skočiti na strijelčevu bolju stranu. ■

Prethodna diskusija nas motivira da uvedemo sljedeće pojmove.

Definicija 3.2 Neka je (A_1, A_2, u_1) igra sume-nula dva igrača.

- **Donja vrijednost** igre, u oznaci $\underline{\lambda}$, je *maximin* dobitak na koji može računati prvi igrač, odnosno $\underline{\lambda} = \sup_{a_i \in A_1} \underline{\Lambda}(a_i)$, gdje je $\underline{\Lambda}(a_i) = \inf_{a_j \in A_2} u_1(a_i, a_j)$ minimalni dobitak prvog igrača pri odabiru strategije a_i (po retcima).
- **Gornja vrijednost** igre, u oznaci $\bar{\lambda}$, je *minimax* gubitak koji drugi igrač može iskusiti, odnosno $\bar{\lambda} = \inf_{a_j \in A_2} \bar{\Lambda}(a_j)$, gdje je $\bar{\Lambda}(a_j) = \sup_{a_i \in A_1} u_1(a_i, a_j)$ maksimalni gubitak drugog igrača pri odabiru strategije a_j (po stupcima). ■

Dakle, donja vrijednost je maksimalan dobitak koji prvi igrač može ostvariti u slučaju nepovoljnih ishoda igre, tj. kada drugi igrač odabere nepovoljniju strategiju za prvog igrača. U prethodnom primjeru je to očito $\underline{\lambda} = 0$. S druge strane, gornja vrijednost predstavlja najmanji mogući gubitak drugog igrača u slučajevima kada prvi igrač odabere nepovoljnu strategiju za drugog igrača. Kod igre penala je to $\bar{\lambda} = 2$. Sličnom analizom se lako vidi da kod igre novčića iz Primjera 3.1 slijedi $\underline{\lambda} = -1$, $\bar{\lambda} = 1$.

Iz same definicije donje i gornje vrijednosti očito je $\underline{\Lambda}(a_i) \leq u_1(a_i, a_j) \leq \bar{\Lambda}(a_j)$, odnosno $\underline{\lambda} \leq \bar{\lambda}$. Očito je da prvi igrač teži povećati svoj maximin dobitak, a drugi igrač smanjiti

svoj minimax gubitak te da ravnotežno stanje nastupa kada su te dvije vrijednosti jednake. Takve igre će nam biti od posebnog značaja.

Definicija 3.3 Igra sume-nula (A_1, A_2, u_1) je **strogo određena** ako je $\underline{\lambda} = \bar{\lambda} = V$. Broj V nazivamo **vrijednost igre**. Pritom $a_1 \in A_1$ je optimalna strategija prvog igrača ako je $\underline{\Lambda}(a_1) = V$, a $a_2 \in A_2$ je optimalna strategija drugog igrača ako je $\bar{\Lambda}(a_2) = V$. ■

Dakle, igra novčića i pucanje penala nisu strogo određene igre.

■ **Primjer 3.3 — eng. Battle of the Bismarck Sea.** Tijekom 2. svjetskog rata, 1943. godine, japanski admiral Imamura pokušao je prebaciti svoje trupe preko Pacifika do Nove Gvineje, a američki zapovjednik Kenney ga je u tome htio spriječiti bombardiranjem transporta. Imamura je mogao odabrati bržu sjevernu rutu plovidbe koja traje 2 dana ili južnu rutu od 3 dana, a Kenney je trebao poslati američke avione na jednu od tih dviju ruta. Ako pogriješi, avioni gube 1 dan na vraćanje, no ako pogodi rutu, iskoristit će sve dane za bombardiranje japanske trupe. Pretpostavimo da je Kenney prvi igrač kojem je korisnost (dobitak) broj dana bombardiranja, dok će Imamuri to biti gubitak. ■

Rješenje. S obzirom da se radi o igri sume-nula, u matricu upisujemo samo u_1 za Amerikance (u_2 za Japance je suprotni predznak). Oba igrača imaju dvije strategije sjever (S) ili jug (J):

$$\begin{array}{cc} & \begin{matrix} S & J \end{matrix} \\ \begin{matrix} S \\ J \end{matrix} & \begin{pmatrix} 2 & 2 \\ 1 & 3 \end{pmatrix} \end{array}$$

Analizirajmo maximin dobitak prvog igrača (po retcima): za odabir sjeverne rute, minimalni dobitak mu je $\underline{\Lambda}(S) = 2$, a za južnu rutu $\underline{\Lambda}(J) = 1$; stoga je donja vrijednost igre $\underline{\lambda} = 2$. Pogledajmo sada minimax gubitak drugog igrača (po stupcima): u slučaju sjeverne rute najviše može izgubiti $\bar{\Lambda}(S) = 2$, a u slučaju južne čak $\bar{\Lambda}(J) = 3$; stoga je i gornja vrijednost igre $\bar{\lambda} = 2$. S obzirom da su obje vrijednosti jednake, zaključujemo da je igra strogo određena i da joj je vrijednost $V = 2$ koja se postiže u strateškom profilu (S, S) .

Lako se provjeri da u ovoj igri postoji i čisti Nashov ekvilibrij upravo u (S, S) . To naravno nije slučajnost o čemu nam govori i sljedeća (očekivana) propozicija.

Propozicija 3.1 Igra sume-nula (A_1, A_2, u_1) ima Nashov ekvilibrij u (a_1^*, a_2^*) ako i samo ako je strogo određena igra s vrijednosti $V = u_1(a_1^*, a_2^*)$, pri čemu je a_1^* optimalna strategija prvog igrača, a a_2^* optimalna strategija drugog igrača.

Dakle, Nashov ekvilibrij postoji isključivo kod strogo određenih igara u kojima je maximin dobitak prvog igrača jednak minimax gubitku drugog igrača. U prethodnom povijesnom primjeru upravo se to i dogodilo, zapovjednik Kenney je shvatio da je Imamuri optimalna strategija ići sjevernom rutom, pa je i on odabrao sjevernu rutu.

Točke Nashovog ekvilibrija u strogo određenoj igri sume-nula se još nazivaju i **sedlastim točkama**. Ako se prisjetimo Matematičke analize 2 i to povežemo sa sedlastim točkama funkcija više varijabli, takav naziv ima smisla jer u toj točki jedan igrač maksimizira svoj minimalni dobitak, a drugi igrač minimizira maksimalni gubitak.

3.2 Matrične igre

Do sada smo promatrali samo čiste igre sume-nula. No naravno, kao što smo uveli mješovita proširenja kod bimatričnih igara, i kod igre sume-nula možemo promatrati mješovite strategije.

Definicija 3.4 Matrična igra je mješovito proširenje konačne igre sume-nula s dva igrača, odnosno matrična igra je bimatrična igra sume-nula. ■

Kao i ranije, s obzirom da za pripadne matrice $U^{(1)}$ i $U^{(2)}$ vrijedi $U^{(2)} = -U^{(1)}$, koristit ćemo samo jednu matricu u oznaci U .

Propozicija 3.2 Za matričnu igru U i mješovite strategije $\vec{x}$ prvog igrača i $\vec{y}$ drugog igrača, vrijedi:

$$\underline{\Lambda}(x) = \min_{j \in A_2} \vec{x} U_{ij}, \quad \overline{\Lambda}(y) = \max_{i \in A_1} U_{ij} \vec{y}^T.$$

Podsjetimo se, $\underline{\Lambda}$ predstavlja minimalne dobitke prvog igrača, a $\overline{\Lambda}$ maksimalne gubitke drugog igrača te u ravnotežnom stanju je maksimum od $\underline{\Lambda}$ jednak minimumu od $\overline{\Lambda}$. Također iz prethodnog poglavlja znamo da mješovito proširenje strateške igre uvijek ima Nashov ekvilibrij pa direktno slijedi sljedeći teorem.

Teorem 3.1 — Minimax teorem. Svaka matrična igra je strogo određena, odnosno vrijedi:

$$V = \max_{x \in [0,1]} \underline{\Lambda}(x) = \min_{y \in [0,1]} \overline{\Lambda}(y)$$

Možemo primijetiti da se matrične igre svode na problem linearnog programiranja pa općenito zahtijevaju manju složenost i lakše ih je riješavati nego bimatrične igre.

Štoviše, matrice $n \times 2$ i $2 \times m$ (kada jedan od igrača ima na raspolaganju samo dvije strategije) možemo rješavati direktno što ćemo pokazati u sljedećim primjerima.

■ **Primjer 3.4** Nađite Nashov ekvilibrij i vrijednost matrične igre:

$$U = \begin{bmatrix} 10 & 2 & 4 & 1 \\ 2 & 10 & 8 & 12 \end{bmatrix}$$

Rješenje. Prvo napomenimo da je ovo zapravo specijalni slučaj bimatrične igre, pa ukoliko želimo koristiti postupak najboljeg odgovora iz 2. poglavlja, trebali bismo prvo naći dominantne strategije i svesti matricu na 2×2 . Ponekad je to moguće i igra se može riješiti i na taj način. U ovom konkretno primjeru nema strogo dominantnih strategija pa ćemo stoga primijeniti Propoziciju 3.2 i Teorem 3.1.

Kao i inače, za mješovitu strategiju prvog igrača pišemo $(x, 1-x)$ pa po Teoremu 3.1 imamo:


$$V = \max_{x \in [0,1]} \min_{j \in A_2} (x, 1-x) U_{ij}$$

Dakle, tražimo maksimum od svih minimalnih vrijednosti po segmentima

$$p_1 : 2 + 8x, \quad p_2 : 10 - 8x, \quad p_3 : 8 - 4x, \quad p_4 : 12 - 11x.$$

To se najlakše pronalazi grafički skiciranjem navedenih pravaca. Na Slici 3.1 su podebljane minimalne vrijednosti na cijelom intervalu $[0, 1]$ te uočavamo da se njena

maksimalna vrijednost postiže za $x^* = \frac{1}{2}$ na presjeku pravaca p_1 , p_2 i p_3 . Odnosno, vrijednost igre je $V = 6$, a optimalna strategija prvog igrača je $x^* = (\frac{1}{2}, \frac{1}{2})$.



Slika 3.1: Primjer 3.4

Sada nam preostaje za drugog igrača naći optimalnu (minimax) strategiju (y_1, y_2, y_3, y_4) koja daje vrijednost igre 6. Sa slike je jasno da izbacujemo strategiju p_4 jer u točki x^* daje vrijednost veću od 6. Dakle, tražimo mješovitu strategiju oblika $(y_1, y_2, y_3, 0)$. S obzirom da nijedna kombinacija prve tri strategije ne smije prelaziti 6, zaključujemo da i na rubovima $x = 0$ i $x = 1$ (tj. čiste strategije prvog igrača) mora vrijediti $10y_1 + 2y_2 + 4y_3 = 6$ i $2y_1 + 10y_2 + 8y_3 = 6$. Zajedno uz vjerojatnosni uvjet $y_1 + y_2 + y_3 = 1$, riješavamo sustav tri jednadžbe s tri nepoznanice i dobivamo da je skup optimalnih strategije drugog igrača:

$$y^* = (y_1, 3y_1 - 1, 2 - 4y_1, 0), \quad y_1 \in [\frac{1}{3}, \frac{1}{2}].$$

Prema tome, imamo beskonačno Nashovih ekvilibrija koji daju vrijednost igre 6. Uočimo da ne postoji Nashov ekvilibrij čiste strateške igre, što možemo dobiti i direktno iz početne matrice jer donja i gornja vrijednost igre ($\underline{\lambda} = 2$, $\bar{\lambda} = 8$) nisu jednake. ■

■ **Primjer 3.5** Riješite matričnu igru:

$$U = \begin{bmatrix} 10 & 2 \\ 2 & 10 \\ 4 & 8 \\ 1 & 12 \end{bmatrix}$$

Prvo primijetimo da igra nije strogo određena jer je $\underline{\lambda} = 4$, $\bar{\lambda} = 10$ pa tražimo mješoviti Nashov ekvilibrij.


S obzirom da u ovom slučaju drugi igrač ima na raspolaganju dvije akcije, krećemo sa mješovitom strategijom drugog igrača $(y, 1 - y)$ pa tražimo:

$$V = \min_{y \in [0,1]} \max_{i \in A_1} U_{ij}(y, 1 - y)^T.$$

Dakle, tražimo minimum od svih maksimalnih vrijednosti po segmentima

$$p_1 : 2 + 8y, \quad p_2 : 10 - 8y, \quad p_3 : 8 - 4y, \quad p_4 : 12 - 11y.$$

Na Slici 3.2 su prikazani dobiveni pravci te je podebljen njihov maksimum na $[0, 1]$. Primijecujemo da se minimalna vrijednost postiže na presjeku p_1 i p_4 , odnosno za $y^* = \frac{10}{19}$, a sama vrijednost igre iznosi $V = \frac{118}{19}$.



Slika 3.2: Primjer 3.5

Sada za prvog igrača tražimo optimalnu (maximin) strategiju (x_1, x_2, x_3, x_4) koja daje dobivenu vrijednost V . Sa slike smo vidjeli da ne uključujemo strategije p_2 i p_3 jer za y^* daju vrijednost manju od V pa tražimo mješovitu strategiju oblika $(x_1, 0, 0, x_4)$. S obzirom da nijedna kombinacija strategija ne smije biti ispod V , zaključujemo da i na rubovima mora vrijediti $10x_1 + x_4 = \frac{118}{19}$ i $2x_1 + 12x_4 = \frac{118}{19}$. Zajedno uz vjerojatnosni uvjet $x_1 + x_4 = 1$, rješenje sustava daje jedinstvenu optimalnu strategiju prvog igrača: $x^* = (\frac{11}{19}, 0, 0, \frac{8}{19})$.

Dakle, dobili smo jedan Nashov ekvilibrij $(x^*, y^*) = ((\frac{11}{19}, 0, 0, \frac{8}{19}), (\frac{10}{19}, \frac{9}{19}))$ uz vrijednost igre $V = \frac{118}{19}$.

■ **Primjer 3.6** Riješite matričnu igru:

$$U = \begin{bmatrix} 6 & 0 & 2 \\ 3 & 2 & 1 \\ 0 & 5 & 4 \end{bmatrix}$$

S obzirom da nijedan od igrača nema samo dvije strategije, kao i kod bimatričnih igara, prvo ćemo eliminirati nedominantne strategije. Nema čistih strogih dominacija, no možemo uočiti da mješovita kombinacija $(0.55, 0, 0.45)$ prvog i trećeg retka strogo dominira nad drugim retkom pa ga možemo izbaciti:

$$\begin{bmatrix} 6 & 0 & 2 \\ 0 & 5 & 4 \end{bmatrix}$$

Prvi igrač sada ima dvije strategije pa možemo krenuti s postupkom iz prijašnjih primjera, no radi jednostavnosti možemo provjeriti je li moguće eliminirati neki stupac.

Naime, strategija $(0.25, 0.75, 0)$ drugog igrača strogo dominira nad trećim stupcem pa možemo i njega izbaciti. Pritom treba biti veoma oprezan jer je korisnost drugog igrača negativna pa smo, npr. za prvi redak gledali $0.25 \cdot (-6) > (-2)$, odnosno $1.5 < 2$.

Dakle, sveli smo problem na jednostavnu matricu 2×2


$$\begin{bmatrix} 6 & 0 \\ 0 & 5 \end{bmatrix},$$

za koju možemo tražiti ili maximin za optimalnu strategiju prvog igrača ili minimax za strategiju drugog igrača,

Ako se odlučimo za prvog igrača, tražimo maksimum od minimalnih vrijednosti po segmentima

$$p_1 : 6x, \quad p_2 : 5 - 5x,$$

kao što je prikazano na Slici 3.3.



Slika 3.3: Primjer 3.6

Presjek dvaju pravaca daje $x^* = \frac{5}{11}$, a vrijednost igre je $V = \frac{30}{11}$. Stoga je konačna optimalna strategija prvog igrača $x^* = (\frac{5}{11}, 0, \frac{6}{11})$, gdje smo stavili nula za izbačeni drugi redak. Optimalnu strategiju drugog igrača dobijemo zaključivanjem kao i ranije: mora vrijediti $6y_1 = \frac{30}{11}$, $5y_2 = \frac{30}{11}$ te uz provjeru $y_1 + y_2 = 1$, dobivamo jedinu optimalnu strategiju $y^* = (\frac{5}{11}, \frac{6}{11}, 0)$.

Za kraj napomenimo da smo reduciranu matricu mogli riješiti i traženjem presjeka najboljih odgovora oba igrača kao kod bimatričnih igara 2×2 , no to ostavljamo zainteresiranim čitateljima za vježbu. ■

Vježba 3.1 — MI-2023. Mali Tomica se igra s π -decimalama i želi da nađete Nashov ekvilibrij sljedeće matrične igre:

$$\begin{bmatrix} 3 & 1 & 4 & 1 \\ 5 & 9 & 2 & 6 \end{bmatrix}$$

Kolika je vrijednost ove igre? (p.s. rješenje je nevjerojatno!)

Vježba 3.2 — MI-2024. Mali Tomica je fasciniran prošlogodišnjom igrom s π -decimalama pa ga ove godine zanima ista takva igra, ali s transponiranom matricom:

$$\begin{bmatrix} 3 & 5 \\ 1 & 9 \\ 4 & 2 \\ 1 & 6 \end{bmatrix}$$

- (a) Kolika je donja i gornja vrijednost čiste igre sume-nula?
- (b) Nađite mješovite Nashove ekvilibrije i vrijednost matrične igre.



4. Ekstenzivne igre

4.1 Stabla odluke

4.2 Potpuni Nashov ekvilibrij



5. Kooperativne igre

5.1 Igre s prenosivom korisnosti

5.2 Igre s pogodbom



6. Literatura

- [1] R. Mrazović, Teorija igara, skripta iz predmeta *Teorija igara*, Sveučilište u Zagrebu PMF-Matematički odsjek
- [2] R. B. Myerson, Game Theory: Analysis of conflict, Harvard University Press, Cambridge, London, 1997.
- [3] H. Peters, Game Theory: A Multi-Leveled Approach, Springer Berlin Heidelberg, 2008.