

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

**Proučavanje obrade prirodnog jezika
i modela BERT s primjenom na
detekciju lažnih vijesti**

Lorena Jakić

Voditelj: *doc. dr. sc. Luka Humski*

Zagreb, svibanj 2025.

SADRŽAJ

1. Uvod	1
2. Osnove obrade prirodnog jezika	2
2.1. Uvod u obradu prirodnog jezika	2
2.2. Temeljne tehnike obrade prirodnog jezika	2
2.2.1. Tokenizacija	2
2.2.2. Analiza dijelova govora	3
2.2.3. Lematizacija i izlučivanje korijena riječi	3
2.2.4. Prepoznavanje entiteta	4
2.2.5. Analiza sentimenta	4
3. BERT	5
3.1. Pregled modela	5
3.2. Arhitektura	5
3.3. Višeglava pažnja	7
3.4. Tokenizacija u BERT-u	7
3.5. Tehnike treniranja	8
3.5.1. MLM (engl. <i>Masked Language Mode</i>)	8
3.5.2. NSP (engl. <i>Next Sentence Prediction</i>)	8
3.6. Primjena i ograničenja	9
4. Primjena BERT-a u detekciji lažnih vijesti	10
4.1. Skup podataka	10
4.2. Treniranje	12
4.3. Rezultati	13
5. Zaključak	16
6. Literatura	17

1. Uvod

Razumijevanje ljudskog jezika pomoću računala postalo je jedno od ključnih područja u razvoju umjetne inteligencije. Obrada prirodnog jezika (engl. *Natural Language Processing* – NLP) omogućuje računalima da analiziraju i generiraju tekst na način koji sve više nalikuje ljudskoj komunikaciji. Kako bi se ostvarilo takvo razumijevanje, razvijene su brojne tehnike poput tokenizacije, lematizacije, prepoznavanja entiteta i analize sentimenta, koje čine osnovu svakog sustava za rad s tekстом. U nastavku će ovi pojmovi biti detaljnije razrađeni.

S dolaskom arhitekture transformera i modela poput BERT-a (engl. *Bidirectional Encoder Representations from Transformers*), NLP je doživio veliki napredak. Pojava modela temeljenih na dubokom učenju, a posebno BERT-a, donijela je značajan iskorak u načinu na koji modeli shvaćaju jezik. Zahvaljujući dvosmjernoj obradi konteksta i pažljivo osmišljenoj arhitekturi, BERT omogućuje dublje i preciznije razumijevanje značenja riječi u rečenici.

Kako bi se prikazala praktična snaga ovakvih modela, u ovom se radu analizira i primjena u detekciji lažnih vijesti.

2. Osnove obrade prirodnog jezika

2.1. Uvod u obradu prirodnog jezika

Obrada prirodnog jezika je područje računalne znanosti i umjetne inteligencije koje koristi strojno učenje kako bi omogućila računalima razumijevanje i komunikaciju na ljudskom jeziku [1]. NLP pruža brojne praktične primjene, uključujući analizu sentimenta, sažimanje teksta te generiranje, interpretaciju i klasifikaciju teksta. Razvojem dubokog učenja i velikih jezičnih modela omogućena je napredna obrada jezika.

NLP obuhvaća razne koncepte i tehnike poput tokenizacije, parsiranja i lematizacije, koji će biti detaljnije objašnjeni u nastavku. Važno je napomenuti da će biti spomenute samo neke od mnoštva tehnika.

2.2. Temeljne tehnike obrade prirodnog jezika

2.2.1. Tokenizacija

Tokenizacija je proces rastavljanja teksta na manje jedinice koje nazivamo tokenima. Tokeni mogu predstavljati pojedinačne znakove, riječi ili njihove dijelove. Glavna svrha je razumijevanje ljudskog jezika tako da se tekst podijeli na manje, razumljive dijelove koji se potom mogu lakše obrađivati.

Tokenizacija je ključna tehnika koja se koristi u mnogim područjima obrade prirodnog jezika, kao što su pretraživanje informacija, prevođenje teksta i analiza sentimenta. Na primjer, pri analizi sentimenta, tokenizacija pomaže u identifikaciji ključnih riječi koje mogu ukazivati na pozitivne ili negativne emocije. Isto tako, u sustavima za prevođenje, tokenizacija omogućava preciznije prepoznavanje značenja riječi u različitim jezicima.

Primjer:

Ako imamo rečenicu: “Proizvod je izuzetno koristan i jednostavan.”

Tokenizacija bi mogla podijeliti ovu rečenicu na sljedeće tokene:

[“Proizvod”, “je”, “izuzetno”, “koristan”, “i”, “jednostavan”, “.”]

2.2.2. Analiza dijelova govora

Analiza dijelova govora (engl. *POS tagging*) označava svaku riječ u tekstu s odgovarajućim gramatičkim oznakama poput imenica, glagola, pridjeva itd. Ovo je ključno za razumijevanje sintaktičke strukture rečenica.

Primjer:

Rečenica: "Proizvod je izuzetno koristan i jednostavan."

Proizvod: imenica (NOUN)

je: pomoćni glagol (AUX)

izuzetno: prilog (ADV)

koristan: pridjev (ADJ)

i: veznik (CCONJ)

jednostavan: pridjev (ADJ)

2.2.3. Lematizacija i izlučivanje korijena riječi

Lematizacija (engl. *lemmatization*) koristi morfološku analizu i rječnik kako bi svaku riječ dovela do njenog osnovnog leksičkog oblika (engl. *lemma*). U obzir se uzima dio govora i kontekst, pa je rezultat uvijek stvarna, gramatički ispravna riječ.

Izlučivanje korijena riječi (engl. *stemming*) je proces uklanjanja prefiksa i sufiksa iz riječi pomoću algoritama temeljenih na pravilima kako bi se dobio njihov korijenski oblik (engl. *stem*). Rezultat često nije valjana riječ u jeziku, već samo osnova koja sadrži srž značenja.

Primjer navedenih tehnika nalazi se u tablici 2.1.

Originalna riječ	Izlučivanje korijena riječi	Lematizacija
trčanje	trčan	trčati
mačke	mačk	mačka
bolje	bolj	dobar

Tablica 2.1: Usporedba izlučivanja korijena riječi i lematizacije [2]

2.2.4. Prepoznavanje entiteta

Prepoznavanje entiteta (NER) uključuje identifikaciju i klasifikaciju imena entiteta u tekstu, poput imena osoba, organizacija ili lokacija.

Primjer:

Rečenica: *"Ana je posjetila Split prošli tjedan."*

Prepoznavanje entiteta:

Ana: osoba

Split: lokacija

prošli tjedan: datum

2.2.5. Analiza sentimenta

Analiza sentimenta (engl. *Sentiment Analysis*) je zadatak obrade prirodnog jezika u kojem želimo automatski odrediti emocionalni ton izražen u tekstu. Sentiment u tekstu najčešće se klasificira u tri osnovne kategorije. Pozitivan sentiment označava izraze zadovoljstva, odobravanja ili općenito pozitivnog stava prema nečemu. Negativan sentiment, s druge strane, ukazuje na nezadovoljstvo, kritički ton ili negativno mišljenje. Treća kategorija je neutralan sentiment, koji ne izražava jasno definiranu emociju ili je ton teksta neodređen i ne može se sa sigurnošću svrstati u pozitivan ili negativan sentiment.

Potpuno razumijevanje ljudskog jezika predstavlja izazov za računala. Teško im je prepoznati sarkazam, skrivene ili neizravno izražene emocije. Unatoč tim poteškoćama, analiza sentimenta stalno napreduje zahvaljujući sve naprednijim algoritmima i modelima koji sve bolje uspijevaju prepoznati složenost ljudskih osjećaja izraženih u pisanom tekstu.

3. BERT

3.1. Pregled modela

BERT (engl. *Bidirectional Encoder Representations from Transformers*) predstavlja model u području obrade prirodnog jezika. Razvio ga je Google 2018. godine, a BERT je promijenio način na koji računala razumiju ljudski jezik. Za razliku od prijašnjih modela, BERT analizira tekst u oba smjera, s lijeva na desno i s desna na lijevo, istovremeno. Ovaj dvosmjerni pristup omogućuje mu da bolje razumije kontekst neke riječi na temelju drugih riječi koje joj prethode i slijede, što rezultira znatno preciznijim razumijevanjem jezika.

Cilj svake tehnike obrade prirodnog jezika je razumjeti ljudski jezik onako kako se prirodno izgovara. Treniranje BERT-a odvija se u dvije glavne faze. Prvo, tijekom pretreniranja, model uči jezičke obrasce koristeći zadatke kao što su predviđanje maskiranih riječi i prepoznavanje odnosa među rečenicama. Nakon toga, model se može podesiti na konkretne zadatke poput klasifikacije teksta koristeći manji broj označenih podataka.

3.2. Arhitektura

BERT je model temeljen na arhitekturi transformera. Transformer je model dubokog učenja koji se posebno koristi za obradu sekvenci podataka, kao što su rečenice. Njegova glavna inovacija je mehanizam pažnje (engl. *self-attention*), koji omogućuje modelu da procijeni koliko je svaka riječ u rečenici važna za druge riječi.


Za razliku od nekih drugih modela temeljenih na ovoj arhitekturi, poput GPT-a koji koristi samo dekodirajući dio, BERT koristi isključivo enkodirajući dio transformera. Razlog za to leži u samoj svrsi modela. Naime, BERT nije dizajniran za generiranje teksta, već za duboko razumijevanje jezika.

Enkoder je komponenta transformera koja prima ulazni tekst i pretvara ga u niz kontekstualiziranih vektora koji predstavljaju značenje riječi s obzirom na cijeli tekst. Model se fokusira na razumijevanje značenja riječi unutar njihovog šireg konteksta.

Enkoder se sastoji od više istovjetnih slojeva, a svaki sloj uključuje mehanizam više-glave samopažnje (engl. *multi-head self-attention*), koji omogućuje modelu da paralelno uči različite aspekte odnosa među riječima.

Prije nego što se ulazni tekst pošalje kroz enkoderske slojeve, on se prvo transformira u vektorske prikaze (engl. *input embeddings*).

Transformer bazirana BERT-base arhitektura koja se sastoji od dvanaest enkoderskih blokova prikazana je slikom 3.1. Osim BERT-base modela, postoji i BERT-large model, koji umjesto dvanaest blokova enkodera ima dvadeset i četiri.



Slika 3.1: BERT-base arhitektura [3]

3.3. Višeglava samopažnja

Samopažnja (engl. *self-attention*) omogućuje modelu da za svaku riječ u rečenici procijeni koliko su druge riječi važne za njezino značenje. Na taj način model može bolje razumjeti veze među riječima.

Ulazne riječi pretvaraju se u vektore, a za svaku riječ računaju se tri posebna vektora: upit (engl. *query*) $\mathbf{Q}$, ključ (engl. *key*) $\mathbf{K}$ i vrijednost (engl. *value*) $\mathbf{V}$. Pažnja se računa kao skalarni umnožak između vektora $\mathbf{Q}$ jedne riječi i $\mathbf{K}$ vektora svih ostalih riječi. Dobiveni rezultati dijele se s korijenom dimenzije ključa kako bi se spriječili prenaglašeni rezultati zbog velikih vrijednosti. Nakon toga, ti skalirani rezultati normaliziraju se pomoću funkcije *softmax* [4]:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (3.1)$$

Samopažnja koristi samo jednu glavu pažnje. Višeglava samopažnja (engl. *multi-head self-attention*) proširuje ovaj koncept tako da istovremeno koristi više takvih glava, pri čemu svaka glava uči različite aspekte odnosa među riječima. Na kraju se rezultati svih glava spoje u jedan zajednički vektor i transformiraju pomoću matrice težina $\mathbf{W}^O$.

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (3.2)$$

$$\text{head}_i = \text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) \quad (3.3)$$

3.4. Tokenizacija u BERT-u

Za razliku od klasične tokenizacije gdje se tekst dijeli na riječi ili interpunkcijske znakove, BERT koristi napredniju metodu zvanu *WordPiece*. Osnovna ideja je razbiti riječi na podriječi (engl. *subwords*) tako da se smanji broj nepoznatih riječi, ali i da se zadrži značenje koje model može razumjeti. Na primjer, riječ *igranje* može se tokenizirati kao *igra + ##nje*, gdje simbol *##* označava da je nastavak prethodnog tokena.

U fazi tokenizacije koristi se unaprijed definiran rječnik podriječi. Algoritam pokušava pronaći najdužu moguću sekvencu znakova koja odgovara nekom tokenu iz rječnika. Ako riječ ne može biti predstavljena pomoću dostupnih podtokena, zamjenjuje se posebnom oznakom [UNK] (nepoznata riječ).

Osim *WordPiece* tokenizacije, BERT koristi i posebne tokene za označavanje početka ([CLS]) i kraja sekvenci ([SEP]).

3.5. Tehnike treniranja

3.5.1. MLM (engl. *Masked Language Mode*)

Tijekom faze pretreniranja modela BERT, određeni dijelovi unosa se maskiraju i model se trenira kako bi predvidio koje su to skrivene riječi, oslanjajući se na okolni kontekst.

Prije nego što BERT započne s učenjem, približno 15% riječi u rečenici se odabere za maskiranje. Od tih odabranih riječi, 80% se zamijeni posebnim simbolom [MASK], 10% se zamijeni nasumičnim riječima iz vokabulara, a preostalih 10% ostaje nepromijenjeno. Zadatak modela je rekonstruirati skrivene riječi analizom konteksta u rečenici [5].

Nakon toga, uspoređuje svoja predviđanja sa stvarnim riječima koje su bile maskirane. Predviđanja modela se izražavaju u obliku vjerojatnosti, gdje model navodi koliko je siguran u svoje procjene. Model dodaje klasifikacijski sloj koji uzima izlaz iz enkodera kako bi predvidio maskirane riječi. Svaka riječ u rječniku ima svoju vjerojatnost koja se izračunava putem funkcije aktivacije *softmax*, koja generira distribuciju vjerojatnosti za svaku maskiranu riječ. Za vrijeme treninga, funkcija gubitka se fokusira samo na predviđanja maskiranih riječi, a modelu se dodjeljuju kazne za odstupanja između stvarnih maskiranih riječi i njegovih predviđanja.

Iako trening traje duže od drugih usmjerenijih modela, zbog svoje strategije koja se fokusira samo na maskirane riječi, sporiji napredak u učenju nadoknađuje se njegovom dubljom razumijevanju konteksta.


3.5.2. NSP (engl. *Next Sentence Prediction*)

Dok MLM uči BERT prepoznavati odnose među riječima unutar rečenice, NSP omogućuje modelu razumijevanje povezanosti između rečenica.

Tijekom pretreniranja, BERT koristi parove rečenica kao ulaz, gdje je između njih smješten specijalni separator token ([SEP]). Model zatim treba predvidjeti slijedi li druga rečenica u paru prvu. Ovo je binarni zadatak klasifikacije u kojem BERT predviđa jednu od dvije moguće oznake: "*IsNext*" (ako druga rečenica logički slijedi prvu) ili "*NotNext*" (ako se druga rečenica ne povezuje sa prvom).

Trening u ovom zadatku uključuje učenje modela da donese točne predikcije o povezanosti rečenica. Kroz ovaj proces, BERT ne samo da uči pojedinačne odnose između riječi, već i razumije kako rečenice koherentno funkcioniraju u okviru većeg konteksta. Ovaj pristup pretreniranja doveo je do značajnih poboljšanja u učinkovitosti modela.

Slika 3.2 prikazuje kako zadaci MLM i NSP rade zajedno. U obje rečenice stavljaju se maskirani tokeni, a model na izlazu istovremeno generira predikcije za maskirane riječi i klasificira odnosi li se druga rečenica na prvu (NSP).



Slika 3.2: MLM i NSP [5]

3.6. Primjena i ograničenja

BERT se uspješno primjenjuje u različitim zadacima obrade prirodnog jezika, poput analize sentimenta, prepoznavanja entiteta u tekstu, sažimanja teksta, kao i u pretraživačima i sustavima za prepoznavanje jezika.


Osim osnovne verzije BERT-base, razvijene su i različite varijante modela, kao što su BERT-large, koji sadrži više enkoderskih slojeva, te specifični modeli poput RoBERT, koji koristi modificirani pristup pretreniranja za bolje rezultate na zadacima klasifikacije.

Unatoč odličnim rezultatima, primjena BERT-a nailazi na neke prepreke. Zahtjevanje procesorske snage i memorije ograničava rad većih modela poput BERT-large. Fiksni WordPiece vokabular modelu otežava prepoznavanje rijetkih ili novonastalih pojmova, a pristranosti sadržane u skupovima podataka iz kojih je treniran mogu se reflektirati u njegovim predikcijama.

4. Primjena BERT-a u detekciji lažnih vijesti


4.1. Skup podataka

Za treniranje modela korišten je skup podataka *Fake and Real News Dataset* [6], preuzet s platforme Kaggle. Skup se sastoji od vijesti podijeljenih u dvije klase: lažne (engl. *fake*) i stvarne (engl. *true*), pri čemu svaka vijest sadrži naslov, tekst članka, temu i datum objave. Slika 4.1 prikazuje raspodjelu lažnih i istinitih vijesti. Skup podataka je prilično balansirani, što olakšava treniranje.



Slika 4.1: Skup podataka *Fake and Real News Dataset*

Kao drugi skup podataka korišten je *WELFake* skup [7]. Riječ je o većem i općenitijem skupu podataka. Vijesti su preuzete iz više različitih izvora, što doprinosi raznolikosti podataka i smanjuje rizik od prekomjernog prilagođavanja modela. Svaka vijest u skupu sadrži redni broj, naslov, sadržaj vijesti, te oznaku klase. Skup podataka je uravnotežen, što dodatno olakšava proces treniranja modela. Slika 4.2 prikazuje distribuciju stvarnih i lažnih vijesti unutar ovog skupa.



Slika 4.2: Skup podataka *WELFake*

4.2. Treniranje

BERT je složena arhitektura s velikim brojem parametara. Ako bi se trenirao od početka na relativno malom skupu podataka, model bi vrlo lako došao do prenaučivosti (engl. *overfitting*) zbog svoje složenosti. Stoga se koristiti već unaprijed istrenirani model na velikom skupu podataka, a zatim se prilagodi na specifičnom, manjem skupu podataka. Ovaj proces prilagodbe naziva se fino podešavanje (engl. *fine-tuning*).

Za treniranje modela korišten je unaprijed istrenirani jezični model BERT-base. Ova varijanta odabrana je zbog svoje uravnoteženosti između performansi i računalne zahtjevnosti, budući da je manje resursno zahtjevna u odnosu na BERT-large.

Prije samog treniranja, podaci su podijeljeni u omjeru 70:30, pri čemu je 70% skupa korišteno za treniranje, dok je preostalih 30% ravnomjerno podijeljeno između skupa za validaciju i testnog skupa.

Za pripremu podataka korišten je BertTokenizer. Tokenizacija, koja je objašnjena u prethodnim poglavljima, provedena je kako bi se tekstualni podaci pretvorili u numeričke reprezentacije koje model može razumjeti.

U ovom radu treniranje modela provedeno je korištenjem dvaju pristupa zamrzavanja unaprijed istreniranih arhitektura. U prvom pristupu, cijela unaprijed istrenirana arhitektura bila je zamrznuta. Na tako zamrznutu bazu dodani su dodatni potpuno povezani slojevi koji su se trenirali, dok su težine osnovnog modela ostale fiksne. U drugom pristupu, zamrznut je samo dio slojeva osnovne arhitekture, dok su ostali slojevi trenirali zajedno s novododanim slojevima. Ovaj pristup omogućio je djelomično prilagođavanje modela specifičnostima skupa podataka, uz zadržavanje prednosti prethodnog učenja.

Optimizacija modela provedena je korištenjem AdamW optimizatora, koji je poznat po svojoj robusnosti u treniranju transformera i boljoj kontroli regularizacije putem korektnog dekomponiranja težina (engl. *weight decay*).

Kako bi se pronašao najbolji skup hiperparametara poput stope učenja i veličine minigrupe (engl. *batch*), korištena je tehnika pretraživanja rešetke (engl. *grid search*), koja pretražuje zadani prostor parametara i odabire kombinaciju koja rezultira najboljim rezultatima na skupu za validaciju.

4.3. Rezultati


Prilikom treniranja na prvom skupu podataka zabilježeni su gotovo savršeni rezultati neovisno o odabiru hiperparametara. Takvi rezultati su se činili neuobičajeno visokima, što je potaknulo na razmatranje mogućih razloga. Jedna od pretpostavki je da je skup možda bio jednostavan za klasifikaciju zbog prisutnosti vrlo prepoznatljivih obrazaca u lažnim vijestima, određenih riječi ili fraza koje se rjeđe pojavljuju u stvarnim vijestima, što je modelu omogućilo da se oslanja na površinske jezične značajke, a ne na dublje razumijevanje sadržaja. Međutim, bez dodatnih analiza, ovaj razlog ne može se sa sigurnošću potvrditi.

Kao drugi skup odabran je WELFake skup podataka, koji se činio opširnijim i kvalitetnijim, budući da je sastavljen spajanjem podataka iz različita izvora. U nastavku su rezultati treniranja modela s tim skupom podataka.

U nastavku su prikazani rezultati treniranja na skupu za testiranje, nevidenom skupu. U početku su korištene osnovne vrijednosti hiperparametara, a nakon toga je provedeno pretraživanje hiperparametara metodom ispitivanja više kombinacija vrijednosti za stopu učenja i veličinu minigrupe. Najbolji rezultati postignuti su za:


- stopa učenja = $5e-4$
- veličina minigrupe = 64

Graf 4.3 prikazuje promjenu gubitka (engl. *loss*) tijekom deset epoha treniranja. Uočitava se da gubitak na skupu za treniranje neprestano pada, dok gubitak na skupu za validaciju raste nakon šeste epohe, što upućuje na prenaučenosť modela.



Slika 4.3: Gubitak u ovisnosti o broju epoha

Sličan obrazac vidi se i na grafu 4.4. Naime, točnost na skupu za validaciju stagnira nakon šeste epohe, dok na skupu za treniranje idalje raste. Do toga dolazi jer model postaje sve sigurniji u svoje pogrešne predikcije na skupu za treniranje, dok na validacijskom skupu i dalje ne uspijeva pravilno razdvojiti te primjere. Iz ovih razloga preporučljivo je zaustaviti treniranje nakon šeste epohe kako bi se spriječila prenaučenosť i osigurala bolja generalizacija modela.



Slika 4.4: Točnost u ovisnosti o broju epoha

Tablica 4.1 prikazuje najbolje dobivene rezultate na skupu za testiranje. Treniranje je zaustavljeno na šest epoha uz prethodno navedenu veličinu minigrupe i stopu učenja.

Korištene mjere su preciznost, odziv i F1-mjera. Preciznost označava koliko su točne pozitivne predikcije modela (od svih predviđenih pozitivnih, koliko ih je stvarno pozitivno). Odziv pokazuje koliko dobro model prepoznaje sve stvarne pozitivne primjere (od svih stvarno pozitivnih, koliko ih je model ispravno prepoznao). F1-mjera predstavlja harmonijsku sredinu između preciznosti i odziva.

Klasa	Preciznost	Odziv	F1-mjera	Broj primjera
Stvarne vijesti	0,89	0,88	0,88	5483
Lažne vijesti	0,86	0,87	0,87	5254
Ukupno	0,88	0,87	0,87	10737

Tablica 4.1: Rezultati klasifikacije na skupu podataka *WELFake*

Model postiže visoku učinkovitost u razlikovanju stvarnih i lažnih vijesti, s F1-mjerom od 0.87 za obje klase, što upućuje na dobru sposobnost generalizacije. Preciznost i odziv su gotovo jednaki za obje klase, što znači da model ne propušta često stvarne primjere lažnih vijesti, niti prekomjerno klasificira stvarne vijesti kao lažne.

Rezultati pokazuju da nije primijećena značajna razlika u performansama između pristupa u kojem je cijela unaprijed istrenirana arhitektura bila zamrznuta i pristupa u kojem je zamrznut samo dio slojeva osnovne arhitekture, dok su ostali trenirani zajedno s novododanim slojevima. Međutim, treniranje bez potpunog zamrzavanja bilo je računalno zahtjevnije. Stoga, s obzirom na odnos između kvalitete rezultata i složenosti treniranja, pristup s potpunim zamrzavanjem osnovne arhitekture pokazuje se efikasnijim.

5. Zaključak

Obrada prirodnog jezika vrlo je zahtjevno i široko područje koje se neprestano razvija. Cilj ovog rada bio je približiti osnovne pojmove i metode iz NLP-a kroz teorijski dio, a zatim ih primijeniti u praksi na konkretnom zadatku.

Kroz implementaciju modela i analizu rezultata pokazano je da model BERT može vrlo učinkovito prepoznati obrasce i značenja u tekstu te na temelju toga klasificirati vijesti kao lažne ili istinite. Dodatnim pretraživanjem parametara postoji vjerojarnost da bi se postigli i bolji rezultati.

U budućnosti bi se istraživanje moglo proširiti na više smjerova. Primjerice, moguće je usporediti različite pretrenirane jezične modele (npr. RoBERTa, XLNet, DeBERTa) ili koristiti višejezične verzije modela. Također, zanimljivo bi bilo istražiti robusnost modela u stvarnim, dinamičnim okruženjima, gdje se sadržaj brzo mijenja.

6. Literatura

- [1] IBM. Natural language processing. <https://www.ibm.com/think/topics/natural-language-processing>, 2024.
- [2] EITCA Academy. What is the difference between lemmatization and stemming in text processing? <https://eitca.org/artificial-intelligence/eitc-ai-dltf-deep-learning-with-tensorflow/tensorflow/processing-data/examination-review-processing-data/what-is-the-difference-between-lemmatization-and-stemming-in-text-processing/>, 2023.
- [3] Xipeng Qiu, Tianxiang Sun, Yige Xu, Yunfan Shao, Ning Dai, and Xuanjing Huang. A survey on BERT-based transfer learning for natural language processing. *arXiv preprint arXiv:2003.12388*, 2020. doi: 10.48550/arXiv.2003.12388. URL <https://arxiv.org/abs/2003.12388>.
- [4] Shanshan Wang, Zhumin Chen, Zhaochun Ren, Huasheng Liang, Qiang Yan, and Pengjie Ren. Paying more attention to self-attention: Improving pre-trained language models via attention guiding, 2022. URL <https://arxiv.org/abs/2204.02922>.
- [5] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. 2018. doi: 10.48550/arXiv.1810.04805. URL <https://arxiv.org/abs/1810.04805>.
- [6] Clément Bisailon. Fake and real news dataset, 2020. URL <https://www.kaggle.com/datasets/clmentbisailon/fake-and-real-news-dataset>.
- [7] Pawan Kumar Verma, Prateek Agrawal, and Radu Prodan. Welfake dataset for fake news detection in text data, 2021. URL <https://doi.org/10.5281/zenodo.4561253>.